

Introducción a la Econometría

Eco 360, Unidad 1

Luis Fernando Escobar

II semestre - 2026

Prólogo

La estadística nos rodea

¿Por qué se necesita comprender la estadística?

Las estadísticas nos rodean, nos persiguen y nos acosan (Sosa, 2017). Están presentes tanto en asuntos cotidianos como en cuestiones de carácter técnico. Por ejemplo, nos preguntamos: ¿Escuchaste cómo va a estar el tiempo hoy?, ¿cuánto habrá sido mi calificación en el examen? ¿sabes si va a hacer frío el fin de semana? Asimismo, en diferentes ámbitos profesionales y científicos surgen preguntas como: ¿Cuál es la efectividad de la policía para combatir el crimen?, ¿cuál es el efecto de un nuevo fertilizante sobre la producción?, ¿cuál es el nivel de pobreza y qué factores influyen en ella?, ¿existe discriminación en el mercado laboral?, ¿cuál es la efectividad de las vacunas frente al COVID-19?, ¿fumar es perjudicial para la salud? o ¿la implementación de un impuesto al tabaco puede generar mayores ingresos para el Estado?

En este sentido, las estadísticas están presentes en diferentes ámbitos, como el económico, social, político, médico, meteorológico, alimentario y deportivo, entre otros. Muchas de estas mediciones forman parte de nuestra vida cotidiana y, aunque no siempre somos conscientes de ello, influyen en las decisiones que tomamos.

La estadística constituye una herramienta fundamental para el desarrollo de la investigación científica. El investigador recurre a métodos estadísticos para contrastar hipótesis, comparar resultados, identificar patrones, establecer relaciones entre variables y formular conclusiones y recomendaciones. En este sentido, la estadística permite abordar problemas de manera sistemática y establecer criterios de decisión en situaciones caracterizadas por la incertidumbre.

La estadística nos rodea

El conocimiento teórico proporciona las bases para desarrollar el arte

Lae Sánchez

2 Tipos de cambio

Walter Sosa Escudero

Demasiado flow

La clase pasada

Motivación

En nuestra anterior sesión, se habló:

1. discutimos la **motivación** para estudiar econometría
2. **presentamos** R—por qué lo usamos y qué puede hacer
3. **comenzamos con el contenido de la asignatura** en base material bibliográfico

Modelo Clásico de Regresión Lineal

Población vs. muestra

Modelos y notación

Se escribe el modelo poblacional (simple):

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

y el modelo de regresión estimado, basado en la muestra, como:

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_i + e_i$$

Un modelo de regresión estimado produce estimaciones para cada observación:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$


lo cual nos da la línea de *mejor ajuste* a través del conjunto de datos.

Población vs. muestra

Pregunta: ¿Por qué nos importa la *población vs. muestra*?

Población vs. muestra


Pregunta: ¿Por qué nos importa la *población vs. muestra*?




Población

Población vs. muestra

Pregunta: ¿Por qué nos importa la *población vs. muestra*?



Población




Relación poblacional

$$y_i = 2.53 + 0.57x_i + u_i$$

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

Población vs. muestra


Pregunta: ¿Por qué nos importa la *población vs. muestra*?




Muestra 1: 30 individuos aleatorios

Población vs. muestra

Pregunta: ¿Por qué nos importa la *población vs. muestra*?



Muestra 1: 30 individuos aleatorios



Relación poblacional


$$y_i = 2.53 + 0.57x_i + u_i$$

Relación muestral


$$\hat{y}_i = 2.36 + 0.61x_i$$

Población vs. muestra

Pregunta: ¿Por qué nos importa la *población vs. muestra*?



Muestra 2: 30 individuos aleatorios



Relación poblacional


$$y_i = 2.53 + 0.57x_i + u_i$$

Relación muestral


$$\hat{y}_i = 2.79 + 0.56x_i$$

Población vs. muestra

Pregunta: ¿Por qué nos importa la *población vs. muestra*?



Muestra 3: 30 individuos aleatorios



Relación poblacional

$$y_i = 2.53 + 0.57x_i + u_i$$


Relación muestral

$$\hat{y}_i = 3.21 + 0.45x_i$$

Repitamos esto **10,000 veces**.


(Este ejercicio se llama una simulación (Monte Carlo).)

Población vs. muestra



Población vs. muestra

Question: Why do we care about *population vs. sample*?



- En **promedio**, nuestras líneas de regresión coinciden muy bien con la línea poblacional.
- Sin embargo, **líneas individuales** (muestras) pueden errar bastante el objetivo.
- Las diferencias entre muestras individuales y la población generan **incertidumbre** para el econometrista.

Población vs. muestra

Question: Why do we care about *population vs. sample*?

Pregunta: ¿Por qué nos importa la *población vs. muestra*?

Población vs. muestra

Question: Why do we care about *population vs. sample*?

Pregunta: ¿Por qué nos importa la *población vs. muestra*?

Respuesta: La incertidumbre importa.

$\hat{\beta}$ en sí es una variable aleatoria—que depende de la muestra aleatoria. Cuando se toma una muestra y corremos una regresión, no sabemos si se trata de una muestra 'buena' ($\hat{\beta}$ está cerca de β) o una muestra 'mala' (nuestra muestra difiere bastante de la población).

Población vs. muestra

Incertidumbre

Llevar el control de esta incertidumbre será un concepto clave a lo largo de nuestro curso.

- Estimar errores estándar para nuestras estimaciones.
- Probar hipótesis.
- Corregir por heterocedasticidad y autocorrelación.

Población vs. muestra

Incertidumbre

Llevar el control de esta incertidumbre será un concepto clave a lo largo de nuestro curso.

- Estimar errores estándar para nuestras estimaciones.
- Probar hipótesis.
- Corregir por heterocedasticidad y autocorrelación.

Primero, vamos a repasar cómo obtenemos estas estimaciones (inciertas) de regresión.

Regresión lineal

El estimador

Podemos estimar una línea de regresión en **R** (`lm(y ~ x, my_data)`) y en **Stata** (`reg y x`). Pero ¿de dónde vienen estas estimaciones?

Unas diapositivas atrás:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

lo cual nos da la línea de *mejor ajuste* a través de nuestro conjunto de datos.

Pero ¿qué se entiende por la "línea de mejor ajuste"?

Ser el "mejor"

Pregunta: ¿Qué se entiende por la *línea de mejor ajuste*?

Respuestas:


- En general (econometría), *línea de mejor ajuste* significa la línea que minimiza la suma de errores al cuadrado (SSE, *sum of squared errors*):

$$\text{SSE} = \sum_{i=1}^n e_i^2 \quad \text{donde} \quad e_i = y_i - \hat{y}_i$$

- Los **mínimos cuadrados** ordinarios (**OLS**, *Ordinary Least Squares*) minimizan la suma de errores al cuadrado.
- Basado en un conjunto de supuestos (en su mayoría razonables), OLS
 - Es insesgado (y consistente)
 - Es el *mejor* estimador lineal insesgado (de varianza mínima) (BLUE, *Best Linear Unbiased Estimator*)


OLS vs. otras líneas/estimadores

Si consideramos el conjunto de datos que generamos anteriormente.



OLS vs. otras líneas/estimadores


Para cualquier línea $(\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x)$



OLS vs. otras líneas/estimadores

Para cualquier línea $(\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x)$, se puede calcular los errores:


$$e_i = y_i - \hat{y}_i$$



OLS vs. otras líneas/estimadores

Para cualquier línea $(\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x)$, se puede calcular los errores:


$$e_i = y_i - \hat{y}_i$$



OLS vs. otras líneas/estimadores


Para cualquier línea $(\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x)$, se puede calcular los errores:

$$e_i = y_i - \hat{y}_i$$




OLS vs. otras líneas/estimadores

SSE eleva al cuadrado los errores ($\sum e_i^2$): los errores más grandes reciben penalizaciones mayores.



OLS vs. otras líneas/estimadores

La estimación OLS es la combinación de $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimiza SSE.



Formalmente

En la regresión lineal simple, el estimador OLS surge de elegir $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimizan la suma de errores al cuadrado (SSE), *i.e.*,

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \text{SSE}$$

Formalmente

En la regresión lineal simple, el estimador OLS surge de elegir $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimizan la suma de errores al cuadrado (SSE), *i.e.*,

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \text{SSE}$$

pero ya se conoce que $\text{SSE} = \sum_i e_i^2$. Pero ahora se usará las definiciones de e_i y $\hat{y}$.

$$\begin{aligned} e_i^2 &= (y_i - \hat{y}_i)^2 = (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 \\ &= y_i^2 - 2y_i\hat{\beta}_0 - 2y_i\hat{\beta}_1 x_i + \hat{\beta}_0^2 + 2\hat{\beta}_0\hat{\beta}_1 x_i + \hat{\beta}_1^2 x_i^2 \end{aligned}$$

Formalmente

En la regresión lineal simple, el estimador OLS surge de elegir $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimizan la suma de errores al cuadrado (SSE), *i.e.*,

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \text{SSE}$$

pero ya se conoce que $\text{SSE} = \sum_i e_i^2$. Pero ahora se usará las definiciones de e_i y $\hat{y}$.

$$\begin{aligned} e_i^2 &= (y_i - \hat{y}_i)^2 = (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 \\ &= y_i^2 - 2y_i \hat{\beta}_0 - 2y_i \hat{\beta}_1 x_i + \hat{\beta}_0^2 + 2\hat{\beta}_0 \hat{\beta}_1 x_i + \hat{\beta}_1^2 x_i^2 \end{aligned}$$

Recordatorio: Minimizar una función multivariada requiere (1) que las primeras derivadas sean iguales a cero (las *condiciones de 1^{er} orden*) y (2) condiciones de segundo orden (concavidad).

Formalmente

Nos estamos acercando. Necesitamos **minimizar SSE**. Ya mostramos cómo SSE se relaciona con nuestra muestra (nuestros datos: x y y) y nuestras estimaciones (i.e., $\hat{\beta}_0$ y $\hat{\beta}_1$).

$$\text{SSE} = \sum_i e_i^2 = \sum_i \left(y_i^2 - 2y_i\hat{\beta}_0 - 2y_i\hat{\beta}_1x_i + \hat{\beta}_0^2 + 2\hat{\beta}_0\hat{\beta}_1x_i + \hat{\beta}_1^2x_i^2 \right)$$

Para las condiciones de primer orden de la minimización, ahora tomamos las primeras derivadas de SSE respecto a $\hat{\beta}_0$ y $\hat{\beta}_1$.

$$\begin{aligned} \frac{\partial \text{SSE}}{\partial \hat{\beta}_0} &= \sum_i \left(2\hat{\beta}_0 + 2\hat{\beta}_1x_i - 2y_i \right) = 2n\hat{\beta}_0 + 2\hat{\beta}_1 \sum_i x_i - 2 \sum_i y_i \\ &= 2n\hat{\beta}_0 + 2n\hat{\beta}_1\bar{x} - 2n\bar{y} \end{aligned}$$

donde $\bar{x} = \frac{\sum x_i}{n}$ y $\bar{y} = \frac{\sum y_i}{n}$ son las medias muestrales de x y y (tamaño n)

Formalmente

Las condiciones de primer orden establecen que las derivadas son iguales a cero, entonces:

$$\frac{\partial \text{SSE}}{\partial \hat{\beta}_0} = 2n\hat{\beta}_0 + 2n\hat{\beta}_1\bar{x} - 2n\bar{y} = 0$$

lo cual implica

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$$

Ahora para $\hat{\beta}_1$.

Formalmente

Tomamos la derivada de SSE respecto a $\hat{\beta}_1$

$$\begin{aligned}\frac{\partial \text{SSE}}{\partial \hat{\beta}_1} &= \sum_i \left(2\hat{\beta}_0 x_i + 2\hat{\beta}_1 x_i^2 - 2y_i x_i \right) = 2\hat{\beta}_0 \sum_i x_i + 2\hat{\beta}_1 \sum_i x_i^2 - 2 \sum_i y_i x_i \\ &= 2n\hat{\beta}_0 \bar{x} + 2\hat{\beta}_1 \sum_i x_i^2 - 2 \sum_i y_i x_i\end{aligned}$$

la igualamos a cero (condiciones de primer orden, de nuevo)

$$\frac{\partial \text{SSE}}{\partial \hat{\beta}_1} = 2n\hat{\beta}_0 \bar{x} + 2\hat{\beta}_1 \sum_i x_i^2 - 2 \sum_i y_i x_i = 0$$

y sustituimos nuestra relación para $\hat{\beta}_0$, i.e., $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$. Así,

$$2n \left(\bar{y} - \hat{\beta}_1 \bar{x} \right) \bar{x} + 2\hat{\beta}_1 \sum_i x_i^2 - 2 \sum_i y_i x_i = 0$$

Formalmente

Continuando desde la diapositiva anterior

$$2n \left(\bar{y} - \hat{\beta}_1 \bar{x} \right) \bar{x} + 2\hat{\beta}_1 \sum_i x_i^2 - 2 \sum_i y_i x_i = 0$$

multiplicamos

$$2n\bar{y}\bar{x} - 2n\hat{\beta}_1\bar{x}^2 + 2\hat{\beta}_1 \sum_i x_i^2 - 2 \sum_i y_i x_i = 0$$

$$\implies 2\hat{\beta}_1 \left(\sum_i x_i^2 - n\bar{x}^2 \right) = 2 \sum_i y_i x_i - 2n\bar{y}\bar{x}$$

$$\implies \hat{\beta}_1 = \frac{\sum_i y_i x_i - 2n\bar{y}\bar{x}}{\sum_i x_i^2 - n\bar{x}^2} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$$

Formalmente

¡Listo!

Ahora se tiene estimadores OLS para la pendiente

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$$

y el intercepto

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Y ahora sabes de dónde viene la parte de *mínimos cuadrados* en "mínimos cuadrados ordinarios". 🤖

Formalmente

¡Listo!

Ahora se tiene estimadores OLS para la pendiente

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$$

y el intercepto

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Y ahora sabes de dónde viene la parte de *mínimos cuadrados* en "mínimos cuadrados ordinarios". 🤝

Ahora pasamos a los supuestos y las propiedades (implícitas) de OLS.

OLS: Supuestos y propiedades

OLS: Supuestos y propiedades

Propiedades

Pregunta: ¿Qué propiedades nos podrían interesar en un estimador?

OLS: Supuestos y propiedades

Propiedades

Pregunta: ¿Qué propiedades nos podrían interesar en un estimador?

Interrupción: Repasemos primero las propiedades estadísticas.

OLS: Supuestos y propiedades

Propiedades

Repaso: Funciones de densidad

Recordemos que usamos **funciones de densidad de probabilidad** (PDF) para describir la probabilidad de que una **variable aleatoria continua** tome un rango de valores. (El área total = 1.)


Estas PDF caracterizan distribuciones de probabilidad, y las distribuciones más comunes/famosas/populares tienen nombres (*e.g.*, normal, *t*, Gamma).

OLS: Supuestos y propiedades

Propiedades

Repaso: Funciones de densidad

La probabilidad de que una variable aleatoria normal estándar tome un valor entre -2 y 0: $P(-2 \leq X \leq 0) = 0.48$




OLS: Supuestos y propiedades

Propiedades

Repaso: Funciones de densidad

La probabilidad de que una variable aleatoria normal estándar tome un valor entre -1.96 y 1.96: $P(-1.96 \leq X \leq 1.96) = 0.95$




OLS: Supuestos y propiedades

Propiedades

Repaso: Funciones de densidad


La probabilidad de que una variable aleatoria normal estándar tome un valor mayor a 2: $P(X > 2) = 0.023$



OLS: Supuestos y propiedades

Propiedades

Imaginemos que estamos tratando de estimar un parámetro desconocido β , y conocemos las distribuciones de tres estimadores en competencia. ¿Cuál preferiríamos? ¿Cómo decidiríamos?



OLS: Supuestos y propiedades

Propiedades

Pregunta: ¿Qué propiedades nos podrían interesar en un estimador?

OLS: Supuestos y propiedades

Propiedades

Pregunta: ¿Qué propiedades nos podrían interesar en un estimador?

Respuesta uno: Sesgo.

En promedio (después de *muchas* muestras), ¿el estimador tiende hacia el valor correcto?

Más formalmente: ¿La media de la distribución del estimador es igual al parámetro que estima?

$$\text{Bias}_{\beta}(\hat{\beta}) = \mathbf{E}[\hat{\beta}] - \beta$$


OLS: Supuestos y propiedades

Propiedades

Respuesta uno: Sesgo.

Estimador insesgado (unbiased):

$$\mathbf{E}[\hat{\beta}] = \beta$$




OLS: Supuestos y propiedades

Propiedades

Respuesta uno: Sesgo.


Estimador insesgado (unbiased):

$$\mathbf{E}[\hat{\beta}] = \beta$$



Estimador sesgado (biased):

$$\mathbf{E}[\hat{\beta}] \neq \beta$$



OLS: Supuestos y propiedades

Propiedades

Respuesta dos: Varianza.

Las tendencias centrales (medias) de distribuciones en competencia no son lo único que importa. También nos importa la **varianza** de un estimador.


$$\text{Var}(\hat{\beta}) = \mathbf{E}\left[\left(\hat{\beta} - \mathbf{E}[\hat{\beta}]\right)^2\right]$$

Estimadores con menor varianza significan que obtenemos estimaciones más cercanas a la media en cada muestra.

OLS: Supuestos y propiedades

Propiedades

Respuesta dos: Varianza (variance).



OLS: Supuestos y propiedades

Propiedades

Respuesta uno: Sesgo.


Respuesta dos: Varianza.

Perdemos de vista: El equilibrio (trade-off) entre sesgo y varianza.

¿Deberíamos estar dispuestos a aceptar algo de sesgo para reducir la varianza?

En econometría, generalmente nos apegamos a estimadores insesgados (o consistentes). Pero otras disciplinas (especialmente ciencias de la computación) piensan un poco más en este equilibrio.

El equilibrio entre sesgo y varianza.



OLS: Supuestos y propiedades

Propiedades

Como seguramente ya habrán deducido, se puede decir:

- OLS es **insesgado**.
- OLS tiene la **varianza mínima** de todos los estimadores lineales insesgados.

OLS: Supuestos y propiedades

Propiedades

Pero... estas propiedades dependen de un conjunto de supuestos:

1. La relación poblacional es lineal en los parámetros, con una perturbación aditiva.
2. Nuestra variable X es **exógena**, i.e., $\mathbf{E}[u \mid X] = 0$.
3. La variable X tiene variación. Y si hay múltiples variables explicativas, no son perfectamente colineales.
4. Las perturbaciones poblacionales u_i están distribuidas de forma independiente e idéntica como variables aleatorias normales con media cero ($\mathbf{E}[u] = 0$) y varianza σ^2 (i.e., $\mathbf{E}[u^2] = \sigma^2$). La distribución independiente y la media cero implican conjuntamente que $\mathbf{E}[u_i u_j] = 0$ para cualquier $i \neq j$.

OLS: Supuestos y propiedades

Supuestos

Distintos supuestos garantizan distintas propiedades:

- Los supuestos (1), (2) y (3) hacen que OLS sea insesgado.
- El supuesto (4) nos da un estimador insesgado para la varianza de nuestro estimador OLS.

Durante nuestro curso, discutiremos las muchas formas en que la vida real puede **violar estos supuestos**. Por ejemplo:

- Relaciones no lineales en nuestros parámetros/perturbaciones (o mala especificación).
- Perturbaciones que no están idénticamente distribuidas o no son independientes.
- Violaciones de exogeneidad (especialmente el sesgo por variable omitida).

OLS: Supuestos y propiedades

Esperanza condicional

Para muchas aplicaciones, nuestro supuesto más importante es la **exogeneidad**, *i.e.*,

$$E[u \mid X] = 0$$

pero ¿qué significa esto en realidad?

OLS: Supuestos y propiedades

Esperanza condicional

Para muchas aplicaciones, nuestro supuesto más importante es la **exogeneidad**, *i.e.*,

$$E[u \mid X] = 0$$

pero ¿qué significa esto en realidad?


Una forma de pensar en esta definición:

Para *cualquier* valor de X , la media de los residuos debe ser cero.


- *E.g.*, $E[u \mid X = 1] = 0$ y $E[u \mid X = 100] = 0$
- *E.g.*, $E[u \mid X_2 = \text{Mujer}] = 0$ y $E[u \mid X_2 = \text{Hombre}] = 0$
- Nota: $E[u \mid X] = 0$ es más restrictivo que $E[u] = 0$

Gráficamente...

Exogeneidad válida, *i.e.*, $E[u \mid X] = 0$



Exogeneidad inválida, *i.e.*, $E[u \mid X] \neq 0$



Incertidumbre e inferencia

Incertidumbre e inferencia

¿Hay algo más?

Hasta este punto, sabemos que OLS tiene algunas propiedades agradables, y sabemos cómo estimar un intercepto y un coeficiente de pendiente mediante OLS.

Nuestro flujo de trabajo actual:

- Conseguir datos (puntos con valores de x y y)
- Regresionar y sobre x
- Graficar la línea OLS (i.e., $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1$)
- ¿Listo?

Pero ¿cómo **aprendemos** realmente algo de este ejercicio?

Incertidumbre e inferencia

Hay más

Pero ¿cómo **aprendemos** realmente algo de este ejercicio?

- Con base en nuestro valor de $\hat{\beta}_1$, ¿podemos descartar valores previamente hipotetizados?
- ¿Qué tan confiados deberíamos estar en la precisión de nuestras estimaciones?
- ¿Qué tan bien explica nuestro modelo la variación que observamos en y ?

Necesitamos poder lidiar con la incertidumbre. Entra: la **Inferencia**.

Incertidumbre e inferencia

Aprendiendo de nuestros errores

Como señalé nuestra simulación anterior, nuestro problema con la **incertidumbre** es que no sabemos si nuestra estimación muestral está *cerca* o *lejos* del parámetro poblacional desconocido.[†]

Sin embargo, no todo está perdido. Podemos usar los errores ($e_i = y_i - \hat{y}_i$) para tener una idea de qué tan bien explica nuestro modelo la variación observada en y .

Cuando nuestro modelo parece hacer un "buen" trabajo, podríamos confiar un poco más en usarlo para aprender sobre la relación entre y y x .

Ahora solo necesitamos formalizar qué significa realmente un "buen trabajo"

[†]. Excepto cuando nosotros mismos corremos la simulación, razón por la cual nos gustan las simulaciones.

Incertidumbre e inferencia

Aprendiendo de nuestros errores

Primero, estimaremos la varianza de u_i (recordemos: $\text{Var}(u_i) = \sigma^2$) usando nuestros errores al cuadrado, *i.e.*,

$$s^2 = \frac{\sum_i e_i^2}{n - k}$$

donde k da el número de términos de pendiente e interceptos que estimamos (*e.g.*, β_0 y β_1 darían $k = 2$).

s^2 es un estimador insesgado de σ^2 .

Incertidumbre e inferencia

Aprendiendo de nuestros errores

Luego mostramos que la varianza de $\hat{\beta}_1$ (para la regresión lineal simple) es

$$\text{Var}(\hat{\beta}_1) = \frac{s^2}{\sum_i (x_i - \bar{x})^2}$$

lo cual muestra que la varianza de nuestro estimador de pendiente

1. aumenta a medida que nuestras perturbaciones se vuelven más ruidosas
2. disminuye a medida que aumenta la varianza de x

Incertidumbre e inferencia

Aprendiendo de nuestros errores

Más común: El error estándar de $\hat{\beta}_1$

$$\text{SE}(\hat{\beta}_1) = \sqrt{\frac{s^2}{\sum_i (x_i - \bar{x})^2}}$$

Recordemos: El error estándar de un estimador es la desviación estándar de la distribución del estimador.

Incertidumbre e inferencia

Aprendiendo de nuestros errores

La salida de errores estándar es estándar en `lm` de R:

```
tidy(lm(y ~ x, pop_df))
```

```
#> # A tibble: 2 × 5
#>   term          estimate std.error statistic  p.value
#>   <chr>          <dbl>    <dbl>    <dbl>    <dbl>
#> 1 (Intercept)    2.53      0.422      6.00 3.38e- 8
#> 2 x              0.567      0.0793     7.15 1.59e-10
```


Incertidumbre e inferencia

Aprendiendo de nuestros errores

Usamos el error estándar de $\hat{\beta}_1$, junto con $\hat{\beta}_1$ mismo, para aprender sobre el parámetro β_1 .

Después de derivar la distribución de $\hat{\beta}_1$,[†] se tiene dos opciones (relacionadas) para la inferencia estadística formal sobre el parámetro desconocido β_1 :

- **Intervalos de confianza:** Usar la estimación y su error estándar para crear un intervalo que, al repetirse, generalmente contendrá el verdadero parámetro.
- **Pruebas de hipótesis:** Determinar si existe evidencia estadísticamente significativa para rechazar un valor hipotetizado.

[†]: Pista: es normal, con la media y varianza que derivamos arriba

Incertidumbre e inferencia

Intervalos de confianza

Construimos intervalos de confianza de nivel $(1 - \alpha)$ para β_1

$$\hat{\beta}_1 \pm t_{\alpha/2, \text{df}} \text{SE}(\hat{\beta}_1)$$

$t_{\alpha/2, \text{df}}$ denota el cuantil $\alpha/2$ de una dist. t con $n - k$ grados de libertad.


Incertidumbre e inferencia

Intervalos de confianza

Construimos intervalos de confianza de nivel $(1 - \alpha)$ para β_1

$$\hat{\beta}_1 \pm t_{\alpha/2, \text{df}} \text{SE}(\hat{\beta}_1)$$

Por ejemplo, 100 obs., dos coeficientes (*i.e.*, $\hat{\beta}_0$ y $\hat{\beta}_1 \implies k = 2$), y $\alpha = 0.05$ (para un intervalo de confianza del 95%) nos da $t_{0.025, 98} = -1.98$



Incertidumbre e inferencia

Intervalos de confianza

Construimos intervalos de confianza de nivel $(1 - \alpha)$ para β_1

$$\hat{\beta}_1 \pm t_{\alpha/2, df} \text{SE}(\hat{\beta}_1)$$

Ejemplo:

```
lm(y ~ x, data = pop_df) %>% tidy()
```

```
#> # A tibble: 2 × 5
```

#>	term	estimate	std.error	statistic	p.value
#>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
#> 1	(Intercept)	2.53	0.422	6.00	3.38e- 8
#> 2	x	0.567	0.0793	7.15	1.59e-10

Incertidumbre e inferencia

Intervalos de confianza

Construimos intervalos de confianza de nivel $(1 - \alpha)$ para β_1

$$\hat{\beta}_1 \pm t_{\alpha/2, df} \text{SE}(\hat{\beta}_1)$$

Ejemplo:

```
lm(y ~ x, data = pop_df) %>% tidy()
```

```
#> # A tibble: 2 × 5
#>   term          estimate std.error statistic  p.value
#>   <chr>          <dbl>    <dbl>    <dbl>    <dbl>
#> 1 (Intercept)    2.53      0.422      6.00 3.38e- 8
#> 2 x              0.567      0.0793     7.15 1.59e-10
```

Nuestro intervalo de confianza del 95% es entonces

$$0.567 \pm 1.98 \times 0.0793 = [0.410, 0.724]$$

Incertidumbre e inferencia

Intervalos de confianza

Entonces tenemos un intervalo de confianza para β_1 , *i.e.*, $[0.410, 0.724]$.

¿Qué significa?

Incertidumbre e inferencia

Intervalos de confianza

Entonces tenemos un intervalo de confianza para β_1 , *i.e.*, $[0.410, 0.724]$.

¿Qué significa?

Informalmente: El intervalo de confianza nos da una región (intervalo) en la cual podemos depositar cierta confianza de que contiene al parámetro.

Incertidumbre e inferencia

Intervalos de confianza

Entonces tenemos un intervalo de confianza para β_1 , i.e., $[0.410, 0.724]$.

¿Qué significa?

Informalmente: El intervalo de confianza nos da una región (intervalo) en la cual podemos depositar cierta confianza de que contiene al parámetro.

Más formalmente: Si muestreamos repetidamente de nuestra población y construimos intervalos de confianza para cada una de estas muestras, $(1 - \alpha)$ por ciento de nuestros intervalos (e.g., 95%) contendrán el parámetro poblacional *en algún lugar del intervalo*.

Incertidumbre e inferencia

Intervalos de confianza

Entonces tenemos un intervalo de confianza para β_1 , i.e., $[0.410, 0.724]$.

¿Qué significa?

Informalmente: El intervalo de confianza nos da una región (intervalo) en la cual podemos depositar cierta confianza de que contiene al parámetro.

Más formalmente: Si muestreamos repetidamente de nuestra población y construimos intervalos de confianza para cada una de estas muestras, $(1 - \alpha)$ por ciento de nuestros intervalos (e.g., 95%) contendrán el parámetro poblacional *en algún lugar del intervalo*.

Ahora, de vuelta a nuestra simulación...

Incertidumbre e inferencia

Intervalos de confianza

Extrajimos 10,000 muestras (cada una de tamaño $n = 30$) de nuestra población y estimamos nuestro modelo de regresión para cada una de estas simulaciones:

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_i + e_i$$


(repetido 10,000 veces)

Ahora, estimemos intervalos de confianza del 95% para cada uno de estos intervalos...

Incertidumbre e inferencia

Intervalos de confianza

De nuestra simulación anterior: 97.9% de los intervalos de confianza del 95% contienen el verdadero valor del parámetro β_1 .



Incertidumbre e inferencia

Pruebas de hipótesis

En muchas aplicaciones, queremos saber más que una estimación puntual o un rango de valores. Queremos saber qué dice nuestra evidencia estadística sobre teorías existentes.

Queremos probar hipótesis planteadas por funcionarios, políticos, economistas, científicos, amigos, vecinos raros, *etc.*

Ejemplos

- ¿Aumentar la presencia policial **reduce la delincuencia**?
- ¿Construir un muro gigante **reduce la delincuencia**?
- ¿Cerrar el gobierno **afecta negativamente la economía**?
- ¿El cannabis legal **reduce la conducción bajo efectos del alcohol**?
- ¿Los estándares de calidad del aire **mejoran la salud o reducen los empleos**?

Incertidumbre e inferencia

Pruebas de hipótesis

Las pruebas de hipótesis se basan en resultados e intuiciones muy similares.

Aunque ciertamente existe incertidumbre, aún podemos construir pruebas estadísticas *confiables* (rechazando o no rechazando una hipótesis planteada).

Incertidumbre e inferencia

Pruebas de hipótesis

Las pruebas de hipótesis se basan en resultados e intuiciones muy similares.

Aunque ciertamente existe incertidumbre, aún podemos construir pruebas estadísticas *confiables* (rechazando o no rechazando una hipótesis planteada).

Prueba t de OLS Nuestra hipótesis (nula) establece que β_1 es igual a un valor c , i.e., $H_o : \beta_1 = c$

A partir de las propiedades de OLS, podemos mostrar que el estadístico de prueba

$$t_{\text{stat}} = \frac{\hat{\beta}_1 - c}{\text{SE}(\hat{\beta}_1)}$$

Incertidumbre e inferencia

Pruebas de hipótesis

Para una prueba **bilateral** de nivel α , rechazamos la hipótesis nula (y concluimos con la hipótesis alternativa) cuando

$$|t_{\text{stat}}| > |t_{1-\alpha/2, df}|$$

lo cual significa que nuestro **estadístico de prueba es más extremo que el valor crítico**.

Alternativamente, podemos calcular el **valor p** que acompaña a nuestro estadístico de prueba, el cual nos da, en efecto, la probabilidad de observar nuestro estadístico de prueba *o uno más extremo* si la hipótesis nula fuera verdadera.

Valores p muy pequeños (generalmente < 0.05) significan que sería poco probable observar nuestros resultados si la hipótesis nula realmente fuera verdadera. *tendemos a rechazar la nula para valores p menores a 0.05*

Incertidumbre e inferencia

Pruebas de hipótesis

R prueba por defecto hipótesis contra el valor cero.

```
lm(y ~ x, data = pop_df) %>% tidy()
```

```
#> # A tibble: 2 × 5  
#>   term          estimate std.error statistic  p.value  
#>   <chr>          <dbl>     <dbl>     <dbl>    <dbl>  
#> 1 (Intercept)    2.53      0.422      6.00 3.38e- 8  
#> 2 x              0.567     0.0793     7.15 1.59e-10
```


Incertidumbre e inferencia

Pruebas de hipótesis

R prueba por defecto hipótesis contra el valor cero.

```
lm(y ~ x, data = pop_df) %>% tidy()
```

```
#> # A tibble: 2 × 5
#>   term          estimate std.error statistic  p.value
#>   <chr>          <dbl>     <dbl>     <dbl>    <dbl>
#> 1 (Intercept)    2.53      0.422      6.00 3.38e- 8
#> 2 x              0.567     0.0793     7.15 1.59e-10
```

$H_0: \beta_1 = 0$ vs. $H_a: \beta_1 \neq 0$

Incertidumbre e inferencia

Pruebas de hipótesis

R prueba por defecto hipótesis contra el valor cero.

```
lm(y ~ x, data = pop_df) %>% tidy()
```

```
#> # A tibble: 2 × 5
#>   term          estimate std.error statistic  p.value
#>   <chr>          <dbl>     <dbl>     <dbl>    <dbl>
#> 1 (Intercept)    2.53      0.422      6.00 3.38e- 8
#> 2 x              0.567     0.0793     7.15 1.59e-10
```

$H_0: \beta_1 = 0$ vs. $H_a: \beta_1 \neq 0$

$t_{\text{stat}} = 7.15$ y $t_{0.975, 28} = 2.05$

Incertidumbre e inferencia

Pruebas de hipótesis

R prueba por defecto hipótesis contra el valor cero.

```
lm(y ~ x, data = pop_df) %>% tidy()
```

```
#> # A tibble: 2 × 5  
#>   term          estimate std.error statistic  p.value  
#>   <chr>          <dbl>     <dbl>     <dbl>    <dbl>  
#> 1 (Intercept)    2.53      0.422      6.00 3.38e- 8  
#> 2 x              0.567     0.0793     7.15 1.59e-10
```

$H_0: \beta_1 = 0$ vs. $H_a: \beta_1 \neq 0$

$t_{\text{stat}} = 7.15$ y $t_{0.975, 28} = 2.05$ lo cual implica un valor $p < 0.05$

Incertidumbre e inferencia

Pruebas de hipótesis

R prueba por defecto hipótesis contra el valor cero.

```
lm(y ~ x, data = pop_df) %>% tidy()
```

```
#> # A tibble: 2 × 5
#>   term          estimate std.error statistic  p.value
#>   <chr>          <dbl>     <dbl>     <dbl>    <dbl>
#> 1 (Intercept)    2.53      0.422      6.00 3.38e- 8
#> 2 x              0.567     0.0793     7.15 1.59e-10
```

$H_0: \beta_1 = 0$ vs. $H_a: \beta_1 \neq 0$

$t_{\text{stat}} = 7.15$ y $t_{0.975, 28} = 2.05$ lo cual implica un valor $p < 0.05$

Por lo tanto, **rechazamos H_0** .