Modelo Clásico de Regresión Lineal Múltiple

Eco 360, Unidad 3

Luis Fernando Escobar
II Semestre 2026

Introducción

Introducción

El modelo con dos variables, estudiado con amplitud en los unidades anteriores, suele ser inadecuado en la práctica.

- Caso consumo-ingreso: se supuso implícitamente que sólo el ingreso X se relaciona con el consumo Y.
- La teoría económica rara vez es tan simple: muchas otras variables probablemente afectan el gasto de consumo (ej. la riqueza del consumidor).
- La demanda de un bien suele depender no sólo de su propio precio, sino también de precios de bienes competitivos, del ingreso, de la condición social, etc.

Introducción

El modelo con dos variables, estudiado con amplitud en los unidades anteriores, suele ser inadecuado en la práctica.

- Caso consumo-ingreso: se supuso implícitamente que sólo el ingreso X se relaciona con el consumo Y.
- La teoría económica rara vez es tan simple: muchas otras variables probablemente afectan el gasto de consumo (ej. la riqueza del consumidor).
- La demanda de un bien suele depender no sólo de su propio precio, sino también de precios de bienes competitivos, del ingreso, de la condición social, etc.

$\Rightarrow$ se necesita ampliar el modelo simple de regresión con dos variables para considerar modelos con **más de dos variables**: el **análisis de regresión múltiple**.

Regresión múltiple

Más variables explicativas

Pasamos de la **regresión lineal simple** (una variable de resultado y una variable explicativa)

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

hacia el terreno de la **regresión lineal múltiple** (una variable de resultado y múltiples variables explicativas)

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + u_i$$

Regresión múltiple

Más variables explicativas

Pasamos de la **regresión lineal simple** (una variable de resultado y una variable explicativa)

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

hacia el terreno de la **regresión lineal múltiple** (una variable de resultado y múltiples variables explicativas)

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + u_i$$

¿Por qué?

Más variables explicativas

Pasamos de la **regresión lineal simple** (una variable de resultado y una variable explicativa)

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

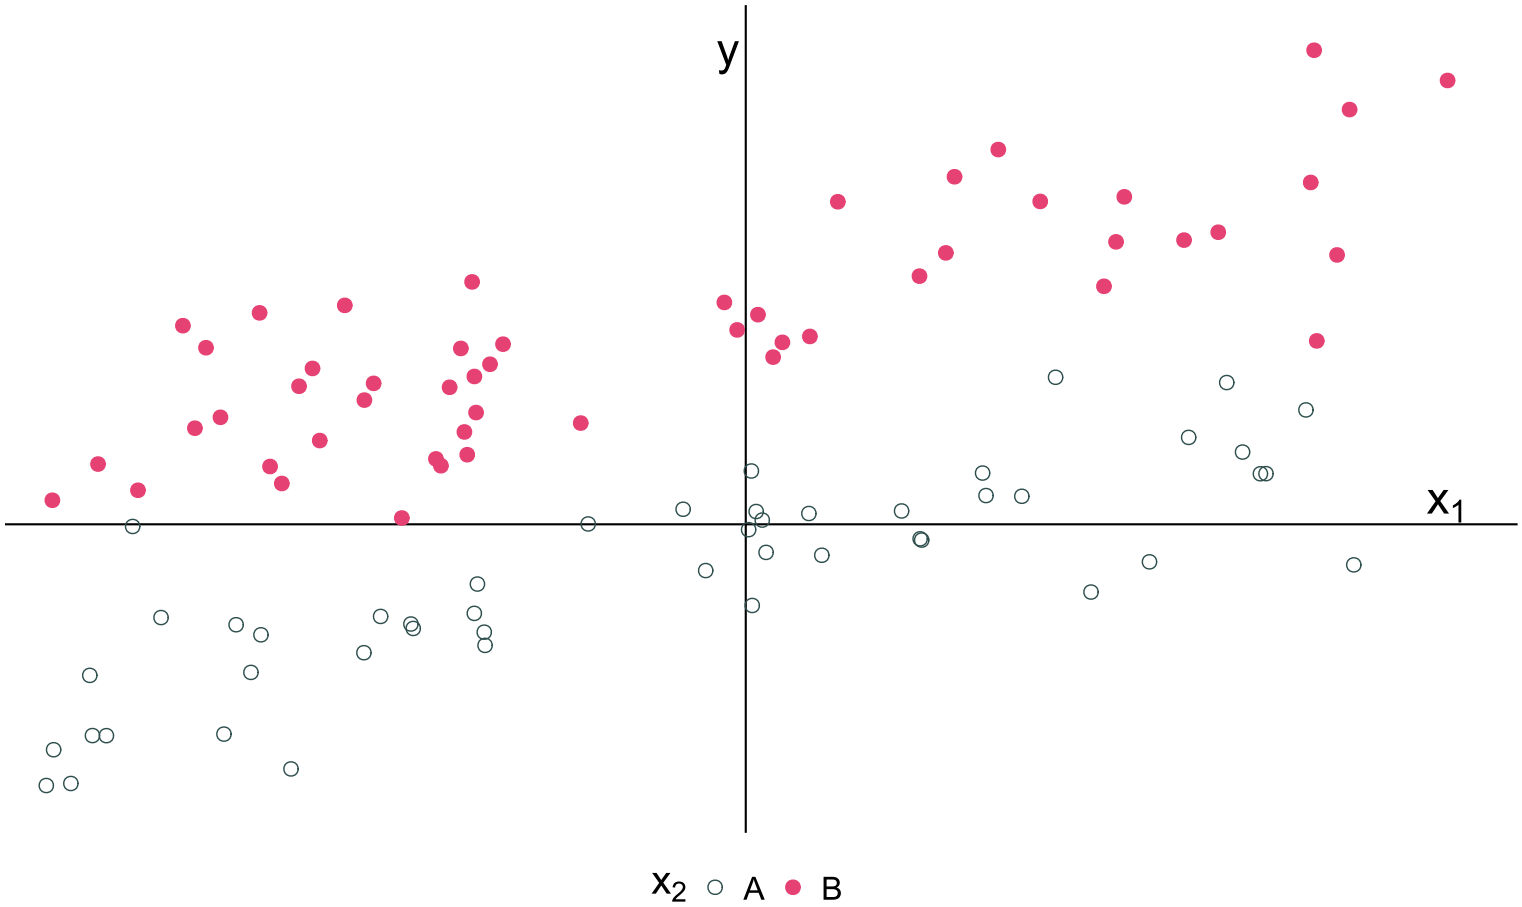
hacia el terreno de la **regresión lineal múltiple** (una variable de resultado y múltiples variables explicativas)

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + u_i$$

¿Por qué? Podemos explicar mejor la variación en y, mejorar las predicciones, evitar el sesgo por variable omitida, ...

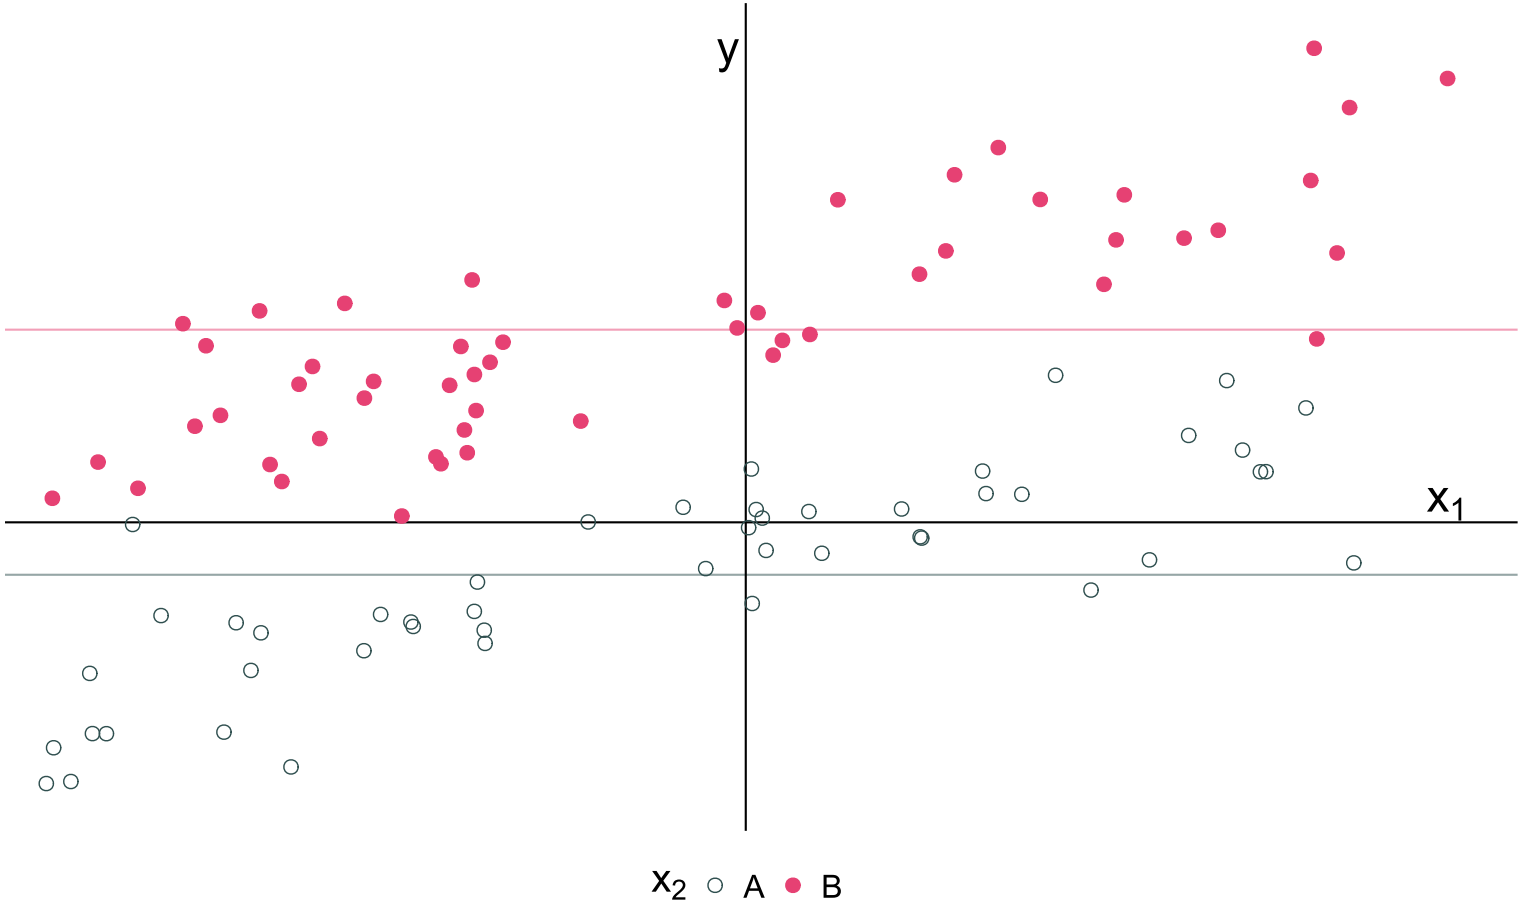
Regresión múltiple

$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i$ x_1 es continua x_2 es categórica



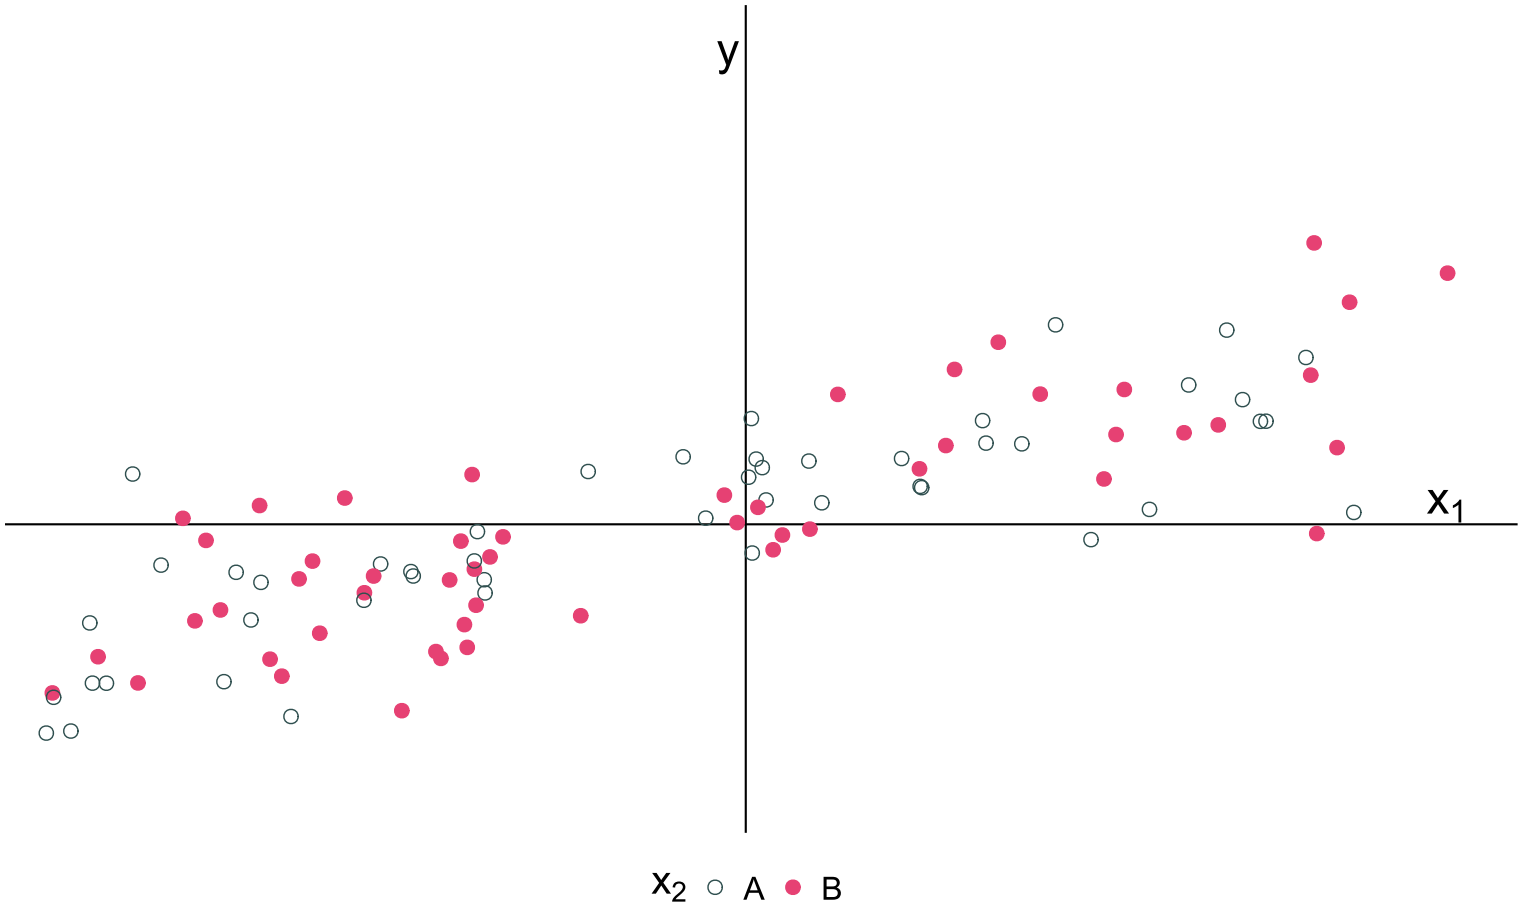
Regresión múltiple

El intercepto y la variable categórica x_2 controlan por las medias de los grupos.



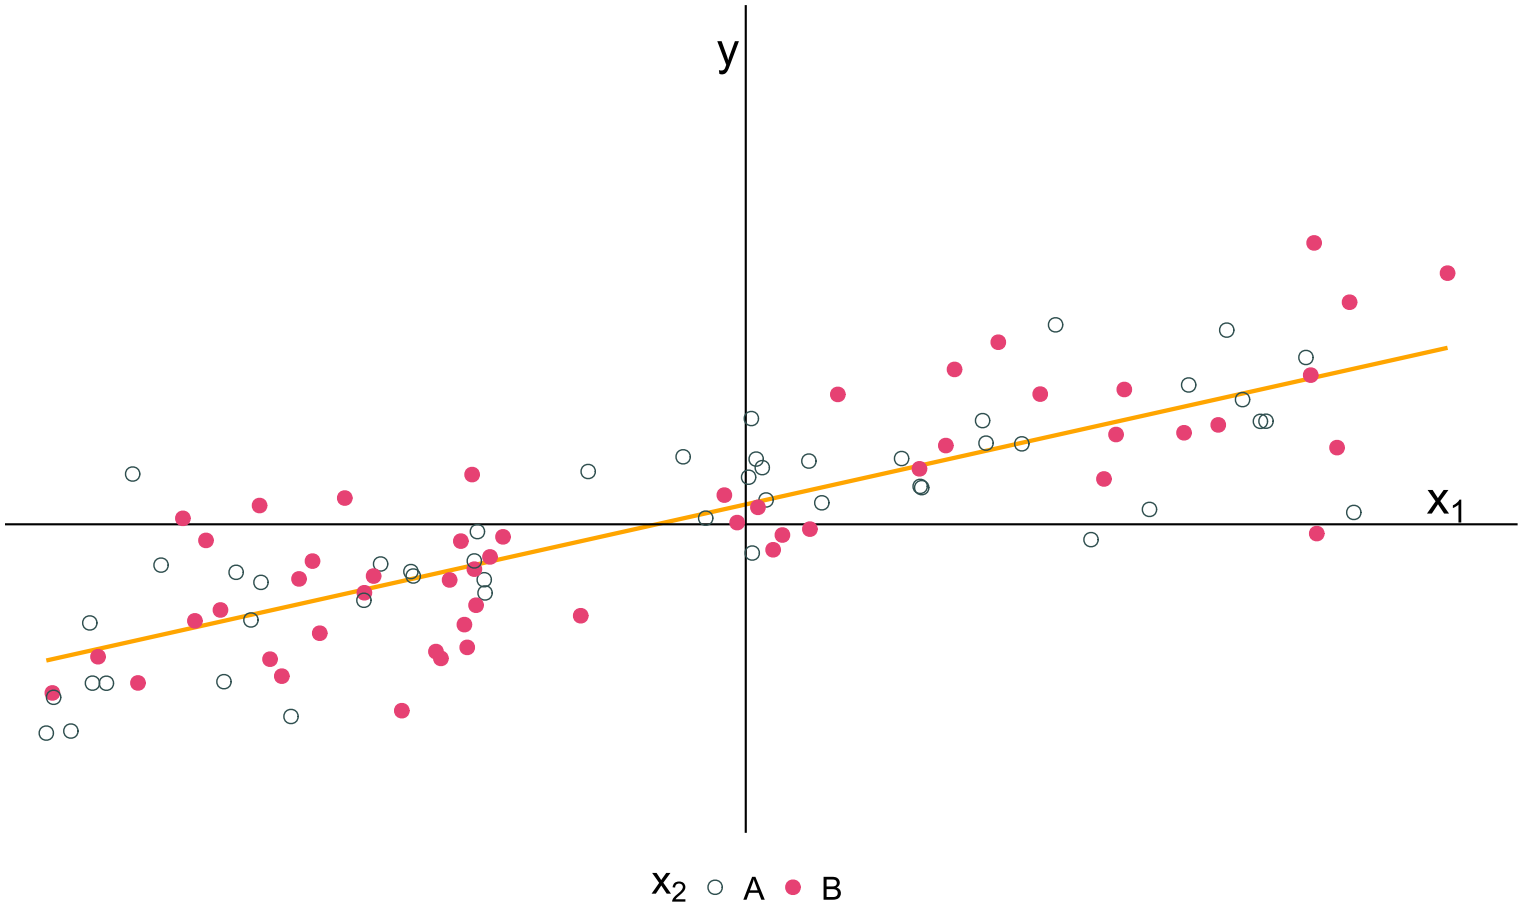
Regresión múltiple

Con las medias de los grupos removidas:



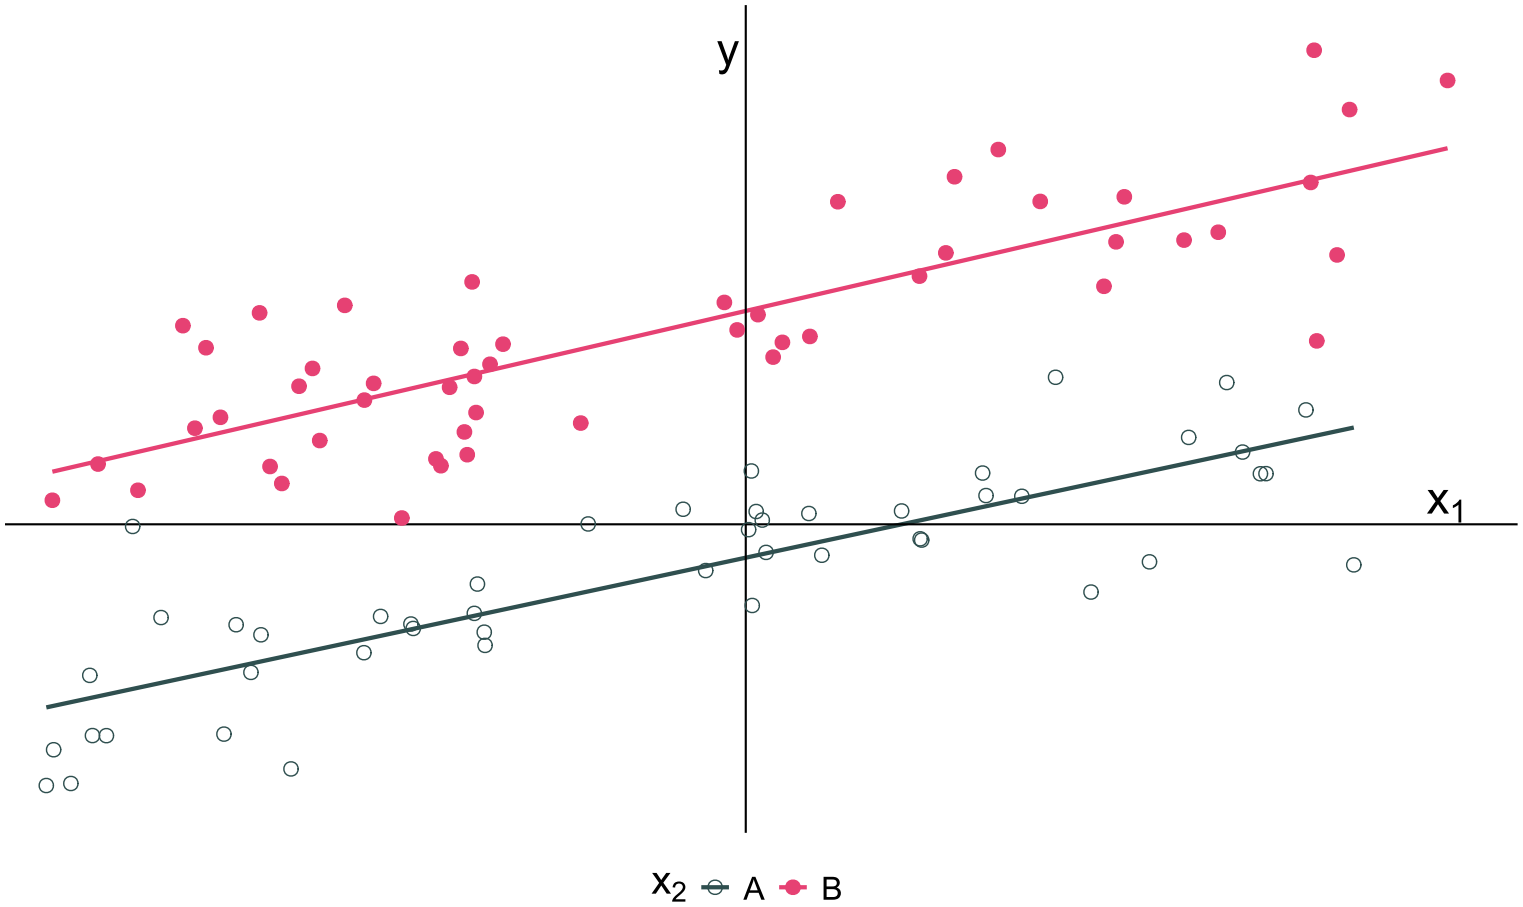
Regresión múltiple

$\hat{\beta}_1$ estima la relación entre y y x_1 después de controlar por x_2.



Regresión múltiple

Otra forma de pensarlo:



Regresión múltiple

Ver nuestro estimador también puede ayudar.

Para la regresión lineal simple $y_i = \beta_0 + \beta_1 x_i + u_i$

$$
\begin{aligned}
\hat{\beta}_1 &= \\
&= \frac{\sum_i \left(x_i - \overline{x}\right)\left(y_i - \overline{y}\right)}{\sum_i \left(x_i - \overline{x}\right)} \\
&= \frac{\sum_i \left(x_i - \overline{x}\right)\left(y_i - \overline{y}\right)/(n-1)}{\sum_i \left(x_i - \overline{x}\right)/(n-1)} \\
&= \frac{\hat{\mathrm{Cov}}(x, y)}{\hat{\mathrm{Var}}(x)}
\end{aligned}
$$

Regresión múltiple

Estimador de la regresión lineal simple:

$$\hat{\beta}_1 = \frac{\hat{\text{Cov}}(x, y)}{\hat{\text{Var}}(x)}$$

al pasar a la regresión lineal múltiple, el estimador cambia ligeramente:

$$\hat{\beta}_1 = \frac{\hat{\text{Cov}}(\tilde{x}_1, y)}{\hat{\text{Var}}(\tilde{x}_1)}$$

donde $\tilde{x}_1$ es la variable x_1 *residualizada*—la variación que queda en x después de controlar por las demás variables explicativas.

Regresión múltiple

Más formalmente, considera el modelo de regresión múltiple

$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u_i$$

Nuestra x_1 residualizada (que llamamos $\tilde{x}_1$) proviene de regresionar x_1 sobre un intercepto y todas las demás variables explicativas, recolectando los residuos, *es decir*,

$$\hat{x}_{1i} = \hat{\gamma}_0 + \hat{\gamma}_2 \, x_{2i} + \hat{\gamma}_3 \, x_{3i}$$
$$\tilde{x}_{1i} = x_{1i} - \hat{x}_{1i}$$

Regresión múltiple

Más formalmente, considera el modelo de regresión múltiple

$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u_i$$

Nuestra x_1 residualizada (que llamamos $\tilde{x}_1$) proviene de regresionar x_1 sobre un intercepto y todas las demás variables explicativas, recolectando los residuos, *es decir*,

$$\begin{aligned} \hat{x}_{1i} &= \hat{\gamma}_0 + \hat{\gamma}_2 \, x_{2i} + \hat{\gamma}_3 \, x_{3i} \\ \tilde{x}_{1i} &= x_{1i} - \hat{x}_{1i} \end{aligned}$$

lo que nos permite entender mejor nuestro estimador de regresión múltiple por MCO

$$\hat{\beta}_1 = \frac{\hat{\text{Cov}}(\tilde{x}_1, \, y)}{\hat{\text{Var}}(\tilde{x}_1)}$$

Ajuste del modelo

Las medidas de *bondad de ajuste* intentan analizar qué tan bien nuestro modelo describe (*ajusta*) los datos.

Medida común: R^2 [R-cuadrado] (*también conocido como* coeficiente de determinación)

$$R^2 = \frac{\sum_i (\hat{y}_i - \bar{y})^2}{\sum_i \left(y_i - \bar{y}\right)^2} = 1 - \frac{\sum_i \left(y_i - \hat{y}_i\right)^2}{\sum_i \left(y_i - \bar{y}\right)^2}$$

Nota nuestro viejo amigo la SSE: $\sum_i \left(y_i - \hat{y}_i\right)^2 = \sum_i e_i^2$.

Ajuste del modelo

Las medidas de *bondad de ajuste* intentan analizar qué tan bien nuestro modelo describe (*ajusta*) los datos.

Medida común: R^2 [R-cuadrado] (*también conocido como* coeficiente de determinación)

$$R^2 = \frac{\sum_i (\hat{y}_i - \bar{y})^2}{\sum_i \left(y_i - \bar{y}\right)^2} = 1 - \frac{\sum_i \left(y_i - \hat{y}_i\right)^2}{\sum_i \left(y_i - \bar{y}\right)^2}$$

Nota nuestro viejo amigo la SSE: $\sum_i \left(y_i - \hat{y}_i\right)^2 = \sum_i e_i^2$.

R^2 literalmente nos dice la proporción de la varianza en y que nuestro modelo actual explica. Por lo tanto $0 \leq R^2 \leq 1$.

Regresión múltiple

El problema: A medida que agregamos variables a nuestro modelo, R^2 aumenta *mecánicamente*.

Regresión múltiple

El problema: A medida que agregamos variables a nuestro modelo, R^2 aumenta *mecánicamente*.

Para ver este problema, podemos simular un conjunto de datos de 10,000 observaciones sobre y y 1,000 variables x_k aleatorias. **¡Sin relación entre y y las x_k!**. Esquema en pseudocódigo de la simulación:

Regresión múltiple

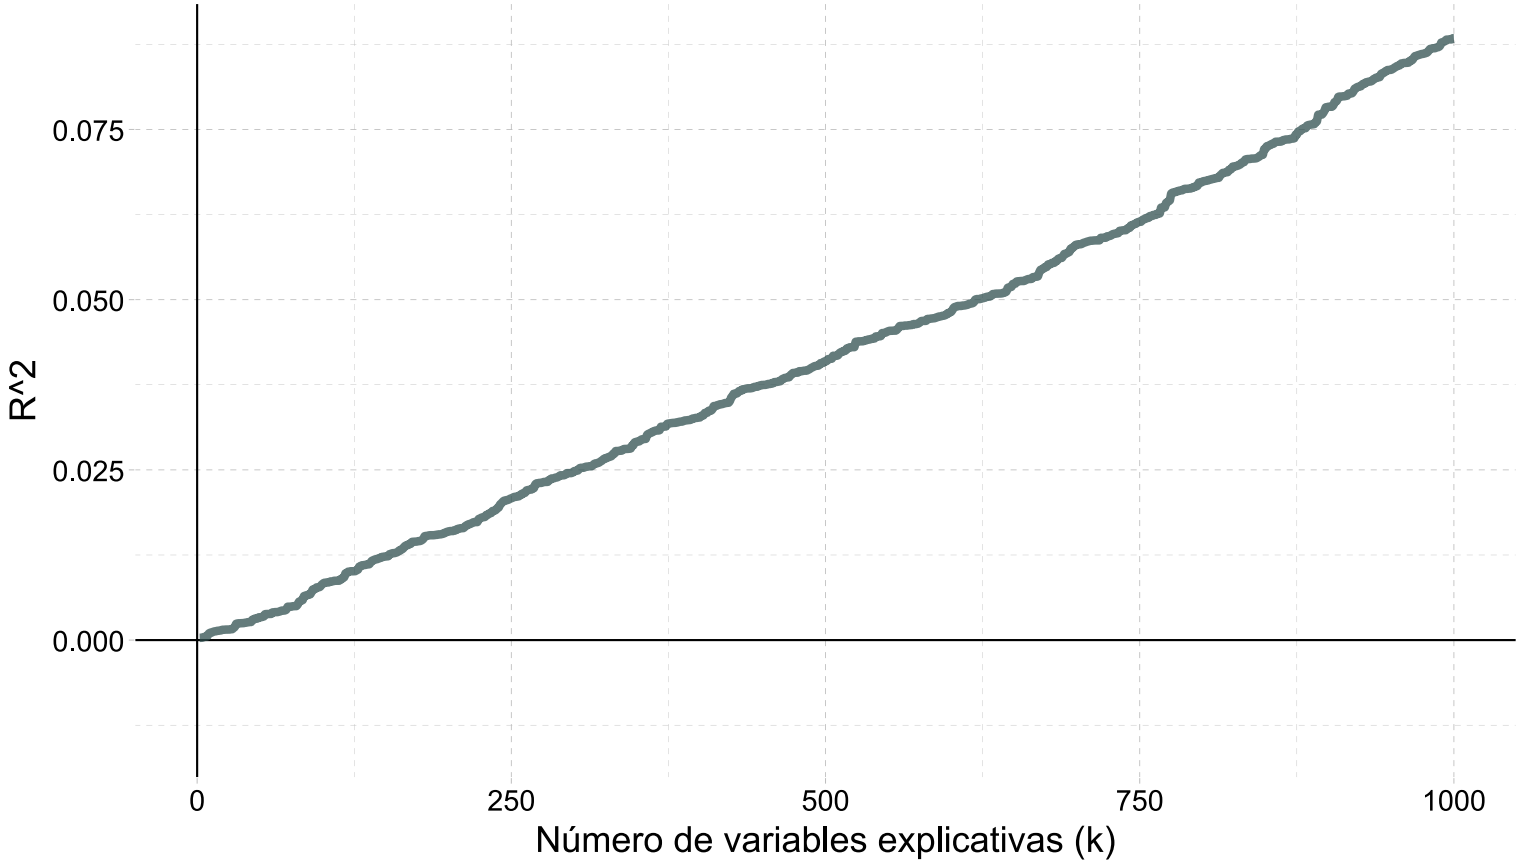
El problema: A medida que agregamos variables a nuestro modelo, R^2 aumenta *mecánicamente*.

Para ver este problema, podemos simular un conjunto de datos de 10,000 observaciones sobre y y 1,000 variables x_k aleatorias. **¡Sin relación entre y y las x_k!**. Esquema en pseudocódigo de la simulación:

- Generar 10,000 observaciones de y
- Generar 10,000 observaciones de las variables x_1 hasta x_{1000}
- Regresiones
  - LM_1: Regresionar y sobre x_1; registrar R^2
  - LM_2: Regresionar y sobre x_1 y x_2; registrar R^2
  - LM_3: Regresionar y sobre x_1, x_2, y x_3; registrar R^2
  - ...
  - LM_{1000}: Regresionar y sobre x_1, x_2, ..., x_{1000}; registrar R^2

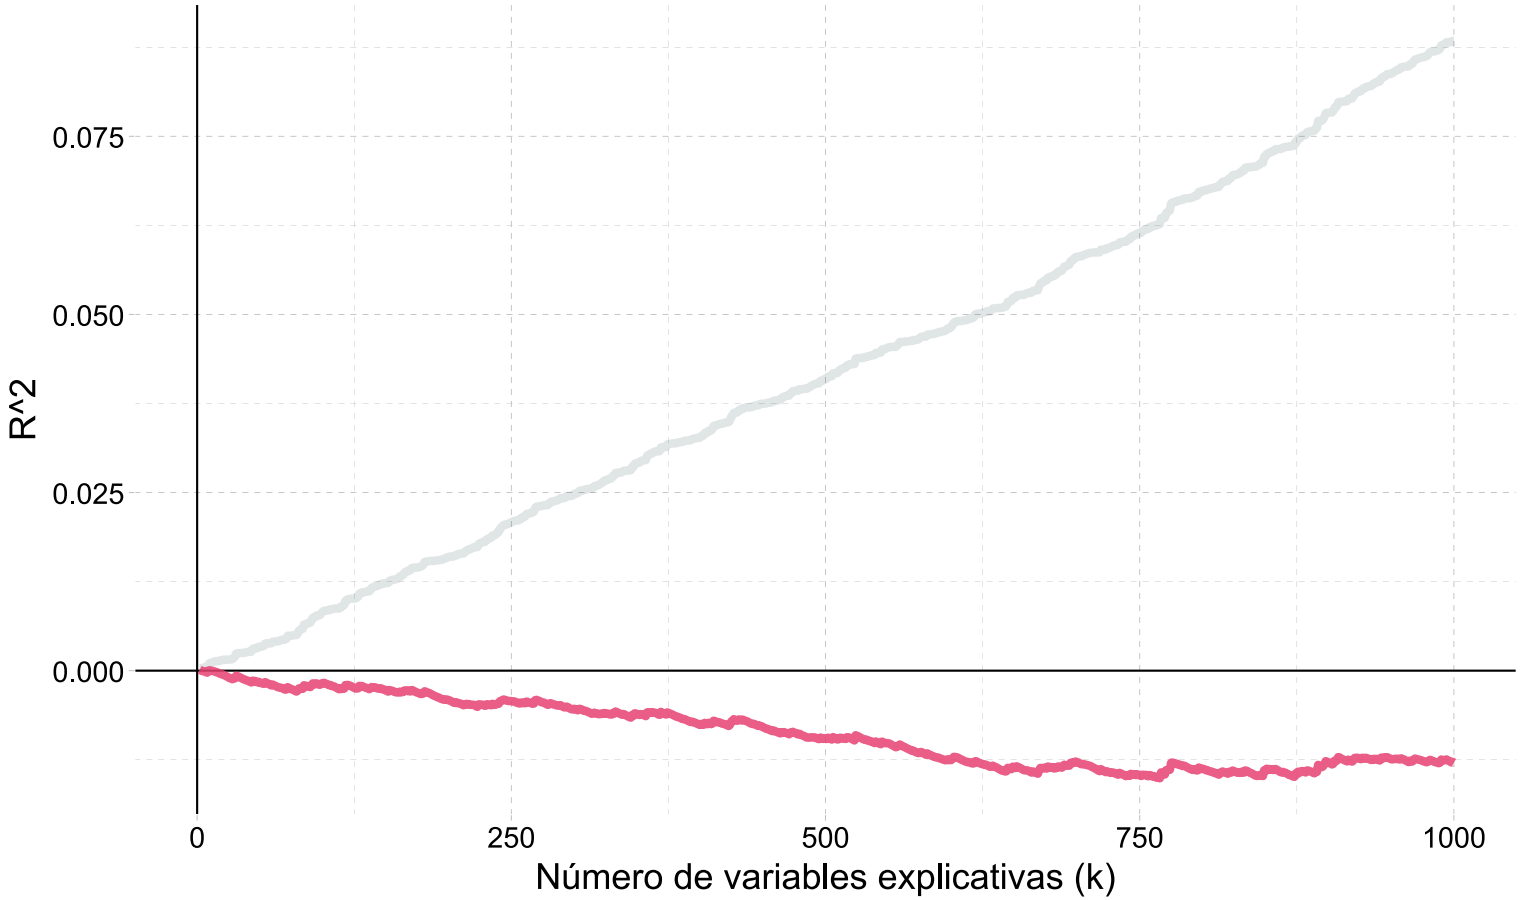
Regresión múltiple

El problema: A medida que agregamos variables a nuestro modelo, R^2 aumenta *mecánicamente*.



Regresión múltiple

Una solución: R^2 Ajustado



Regresión múltiple

El problema: A medida que agregamos variables a nuestro modelo, R^2 aumenta *mecánicamente*.

Una solución: Penalizar por el número de variables, *por ejemplo*, el R^2 ajustado:

$$\overline{R}^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2/(n-k-1)}{\sum_i (y_i - \bar{y})^2/(n-1)}$$

Nota: El R^2 ajustado no necesariamente está entre 0 y 1.

Regresión múltiple

Disyuntivas (tradeoffs). Hay disyuntivas que recordar al agregar/quitar variables:

Menos variables

- Generalmente explican menos variación en y
- Ofrecen interpretaciones y visualizaciones simples (*parsimonia*)
- Puede que haya que preocuparse por el sesgo de variable omitida

Más variables

- Más probable encontrar relaciones *espurias* (estadísticamente significativas por azar—no reflejan una relación verdadera a nivel poblacional)
- Más difícil interpretar el modelo
- Aun así podrías omitir variables importantes—sigue existiendo el sesgo de variable omitida

Sesgo de variable omitida

Sesgo de variable omitida

Profundizaremos en este tema en unas semanas, pero intuitivamente:

El sesgo de variable omitida (OVB, por sus siglas en inglés) surge cuando omitimos una variable que

1. afecta nuestra variable de resultado y
2. se correlaciona con una variable explicativa x_j

Como su nombre lo indica, esta situación genera sesgo en nuestra estimación de β_j.

Sesgo de variable omitida

Profundizaremos en este tema en unas semanas, pero intuitivamente:

El sesgo de variable omitida (OVB, por sus siglas en inglés) surge cuando omitimos una variable que

1. afecta nuestra variable de resultado y
2. se correlaciona con una variable explicativa x_j

Como su nombre lo indica, esta situación genera sesgo en nuestra estimación de β_j.

Nota: El OVB no es exclusivo de la regresión lineal múltiple, pero sí requiere que múltiples variables afecten a y.

Sesgo de variable omitida

Ejemplo

Imaginemos un modelo simple para el monto que se le paga al individuo i

$$\mathbf{Salario}_i = \beta_0 + \beta_1 \mathbf{Escolaridad}_i + \beta_2 \mathbf{Hombre}_i + u_i$$

donde

- $\mathbf{Escolaridad}_i$ da los años de educación de i
- $\mathbf{Hombre}_i$ denota una variable indicadora de si el individuo i es hombre.

por lo tanto

- β_1: el retorno a un año adicional de escolaridad (*ceteris paribus*)
- β_2: la prima por ser hombre (*ceteris paribus*)
  Si $\beta_2 > 0$, entonces hay discriminación contra las mujeres—reciben menos salario en función del género.

Sesgo de variable omitida

Ejemplo, continuación

De nuestro modelo poblacional

$$\text{Salario}_i = \beta_0 + \beta_1 \text{Escolaridad}_i + \beta_2 \text{Hombre}_i + u_i$$

Si un estudio se enfoca en la relación entre el salario y la escolaridad, *es decir*,

$$\text{Salario}_i = \beta_0 + \beta_1 \text{Escolaridad}_i + (\beta_2 \text{Hombre}_i + u_i)$$

$$\text{Salario}_i = \beta_0 + \beta_1 \text{Escolaridad}_i + \varepsilon_i$$

donde $\varepsilon_i = \beta_2 \text{Hombre}_i + u_i$.

Usamos nuestro supuesto de exogeneidad para derivar la insesgadez de MCO. Pero aunque $\boldsymbol{E}[u|X] = 0$, no es cierto que $\boldsymbol{E}[\varepsilon|X] = 0$ siempre que $\beta_2 \neq 0$.

Sesgo de variable omitida

Ejemplo, continuación

Específicamente, $\boldsymbol{E}[\varepsilon|\text{Hombre} = 1] = \beta_2 + \boldsymbol{E}[u|\text{Hombre} = 1] \neq 0$.

Sesgo de variable omitida

Ejemplo, continuación

Específicamente, $\boldsymbol{E}[\varepsilon|\text{Hombre} = 1] = \beta_2 + \boldsymbol{E}[u|\text{Hombre} = 1] \neq 0$. Ahora MCO está sesgado.

Sesgo de variable omitida

Ejemplo, continuación

Específicamente, $\boldsymbol{E}[\varepsilon|\text{Hombre} = 1] = \beta_2 + \boldsymbol{E}[u|\text{Hombre} = 1] \neq 0$. **Ahora MCO está sesgado.**

Intentemos ver este resultado gráficamente.

El modelo poblacional:

$$\text{Salario}_i = 20 + 0.5 \times \text{Escolaridad}_i + 10 \times \text{Hombre}_i + u_i$$

Nuestro modelo de regresión que sufre de sesgo de variable omitida:

$$\text{Salario}_i = \hat{\beta}_0 + \hat{\beta}_1 \times \text{Escolaridad}_i + e_i$$

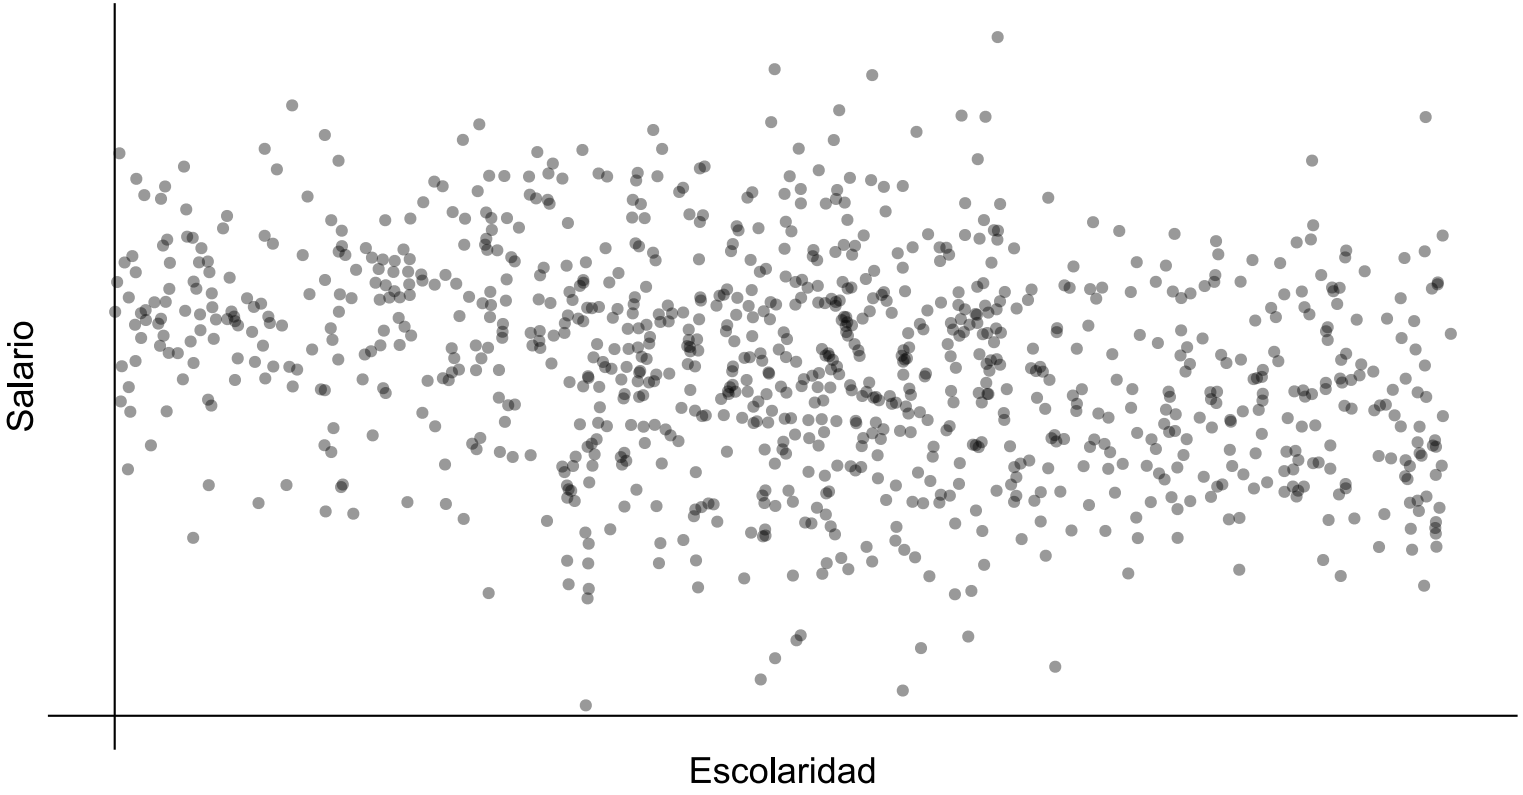
Finalmente, imaginemos que las mujeres, en promedio, reciben más escolaridad que los hombres.

Sesgo de variable omitida

Ejemplo, continuación:

$$\text{Salario}_i = 20 + 0.5 \times \text{Escolaridad}_i + 10 \times \text{Hombre}_i + u_i$$

La relación entre salario y escolaridad.

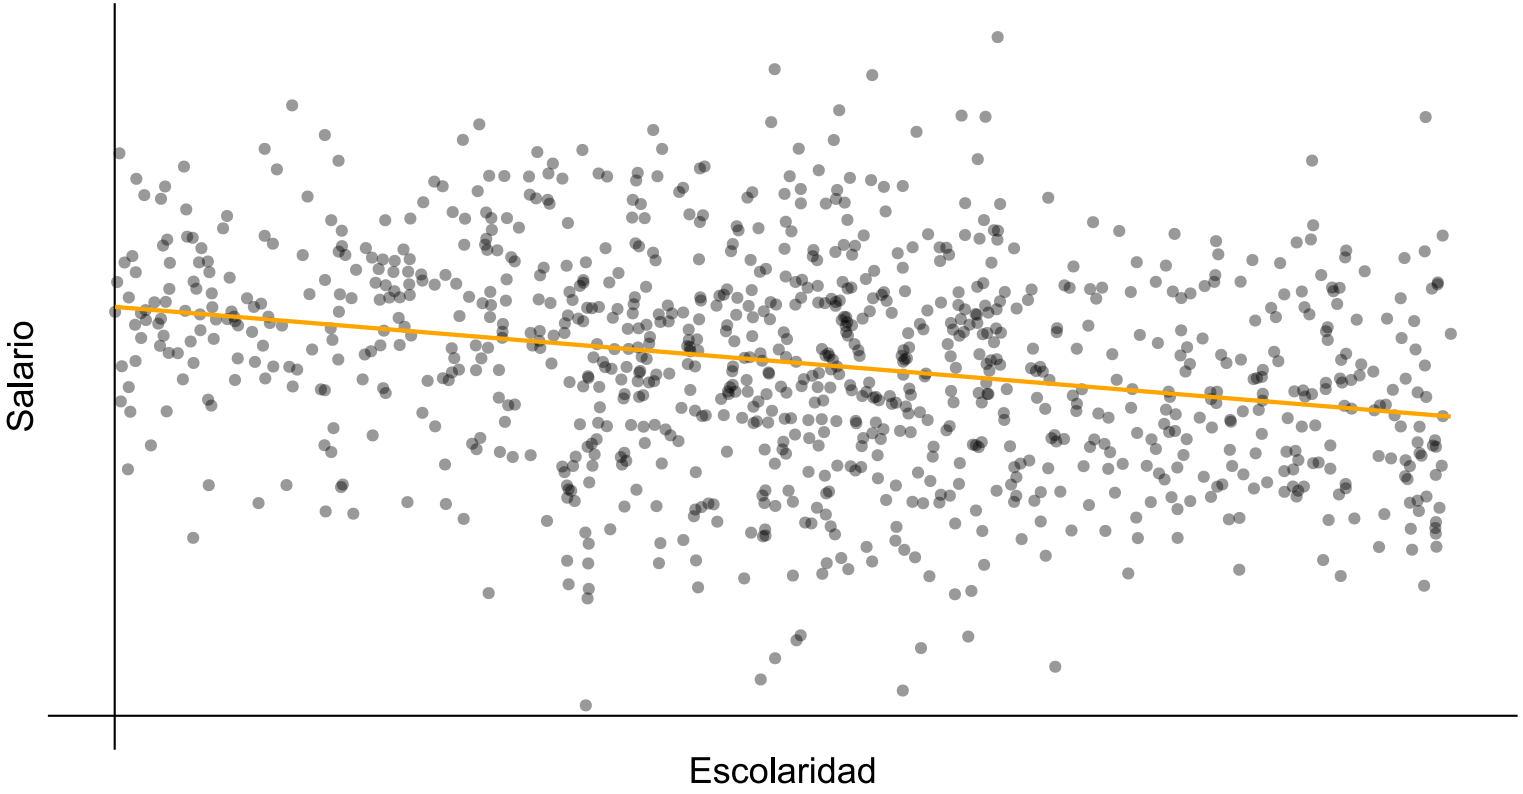


Sesgo de variable omitida

Ejemplo, continuación:

$$\text{Salario}_i = 20 + 0.5 \times \text{Escolaridad}_i + 10 \times \text{Hombre}_i + u_i$$

Estimación de regresión sesgada: $\widehat{\text{Salario}}_i = 31.3 + -0.9 \times \text{Escolaridad}_i$

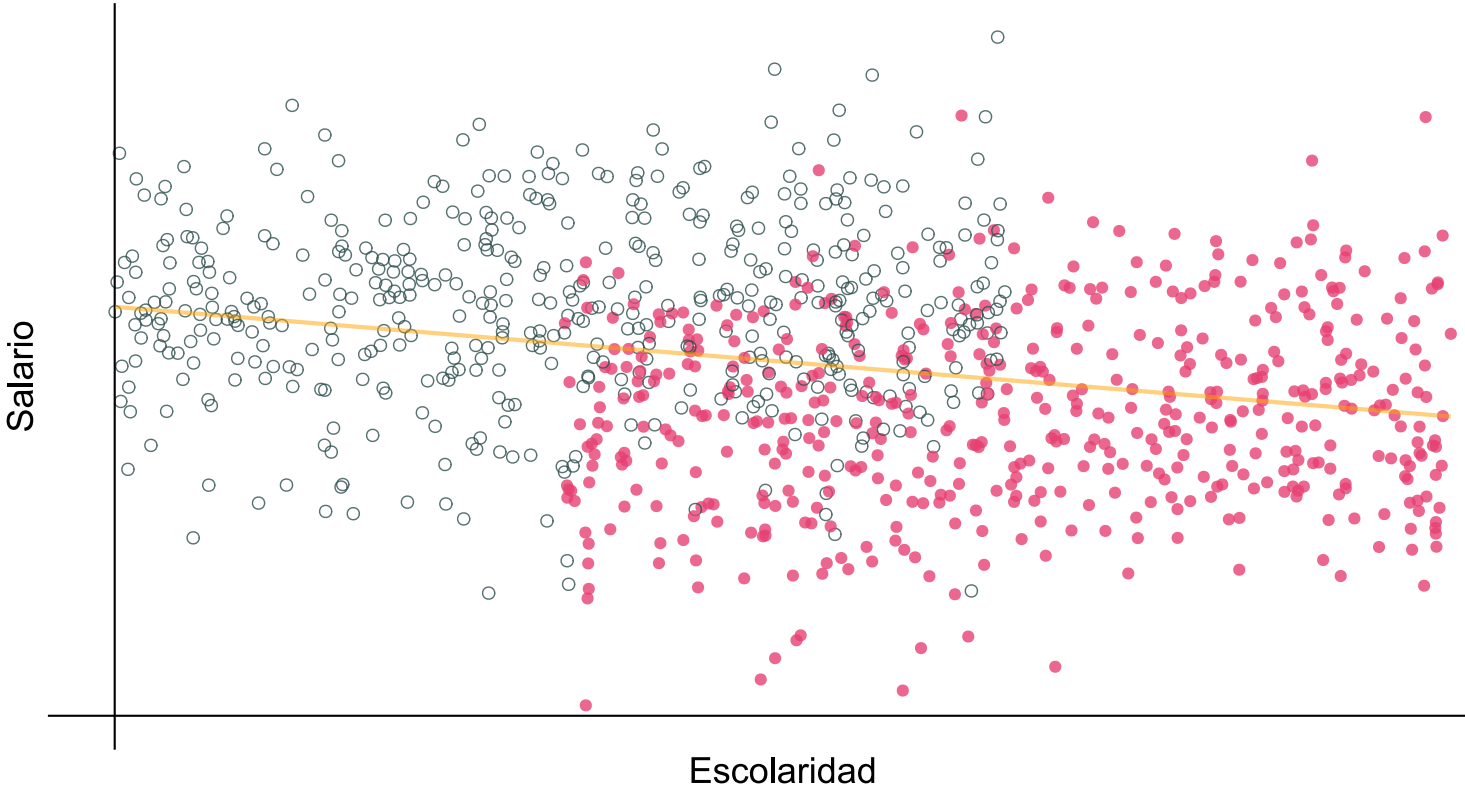


Sesgo de variable omitida

Ejemplo, continuación:

$$\text{Salario}_i = 20 + 0.5 \times \text{Escolaridad}_i + 10 \times \text{Hombre}_i + u_i$$

Recordando la variable omitida: Género (mujer y hombre)

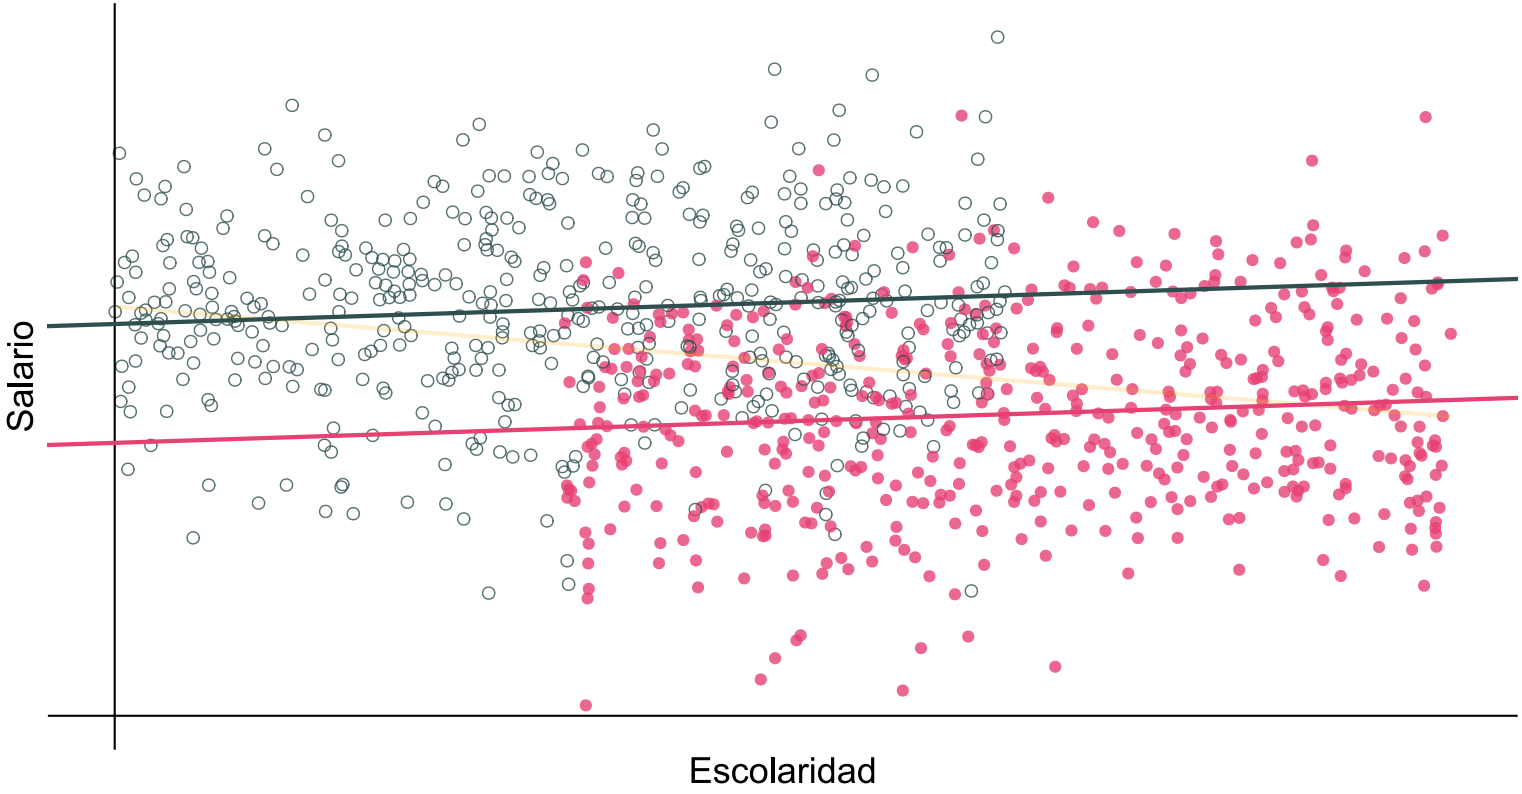


Sesgo de variable omitida

Ejemplo, continuación:

$$\text{Salario}_i = 20 + 0.5 \times \text{Escolaridad}_i + 10 \times \text{Hombre}_i + u_i$$

Recordando la variable omitida: Género (mujer y hombre)



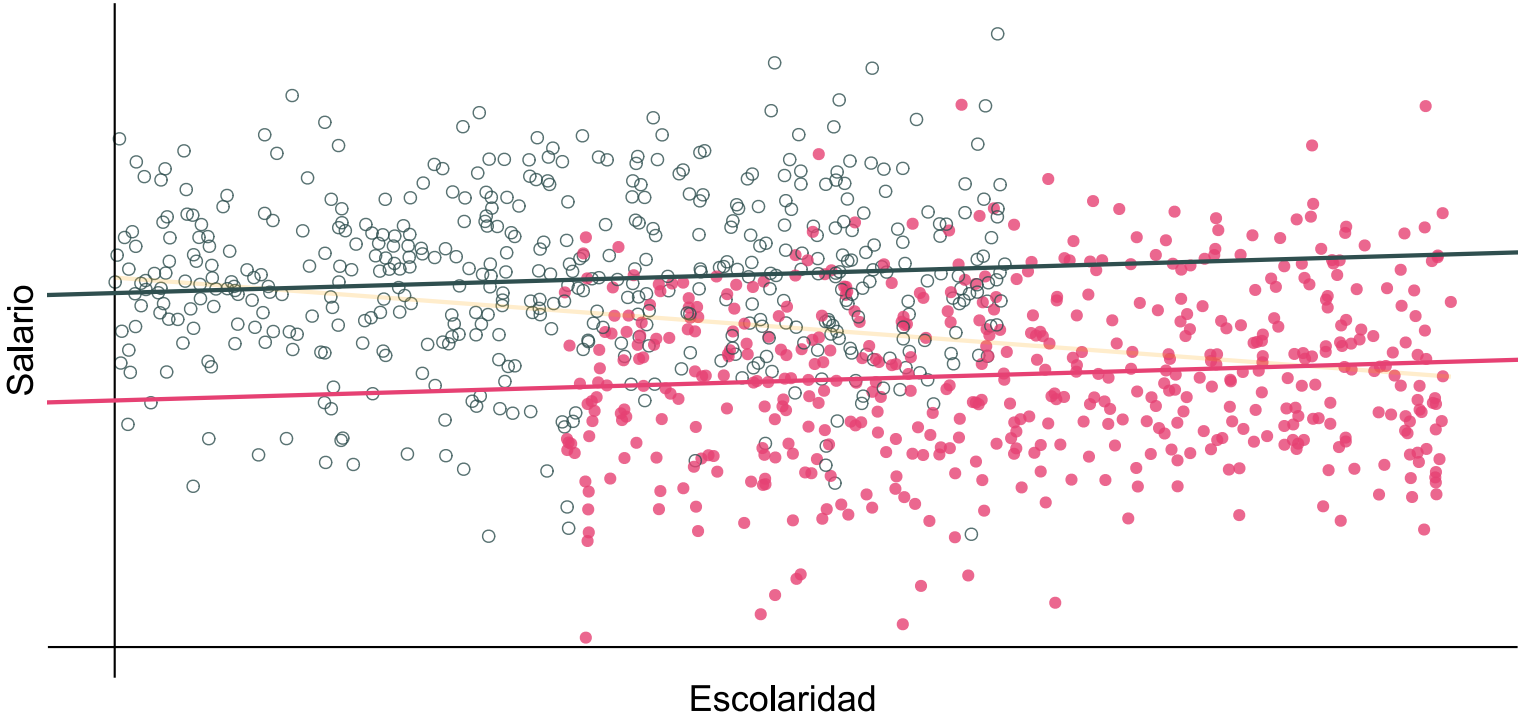
Sesgo de variable omitida

Ejemplo, continuación:

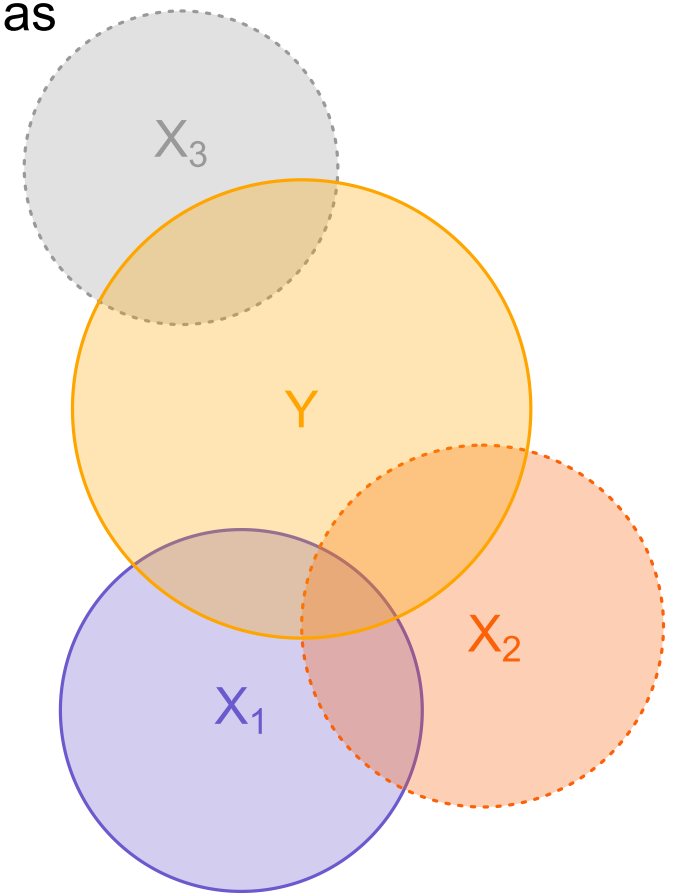
$$\text{Salario}_i = 20 + 0.5 \times \text{Escolaridad}_i + 10 \times \text{Hombre}_i + u_i$$

Estimación de regresión insesgada:

$$\widehat{\text{Salario}}_i = 20.9 + 0.4 \times \text{Escolaridad}_i + 9.1 \times \text{Hombre}_i$$



Variables omitidas



Sesgo de variable omitida

Soluciones

1. No omitir variables

2. Variables instrumentales y mínimos cuadrados en dos etapas[†]

Advertencia: Hay situaciones en las que ninguna solución es posible.

Sesgo de variable omitida

Soluciones

1. No omitir variables

2. Variables instrumentales y mínimos cuadrados en dos etapas[†]

Advertencia: Hay situaciones en las que ninguna solución es posible.

1. Proceder con cautela (a veces puedes determinar el signo del sesgo).

2. Tal vez simplemente detenerse.

[†]: Un curso de econometría II.

Interpretando coeficientes

Interpretando coeficientes

Variables continuas

Considera la relación

$$\mathbf{Salario}_i = \beta_0 + \beta_1 \, \mathbf{Escolaridad}_i + u_i$$

donde

- $\mathbf{Salario}_i$ es una variable continua que mide el salario de un individuo
- $\mathbf{Escolaridad}_i$ es una variable continua que mide los años de educación

Interpretando coeficientes

Variables continuas

Considera la relación

$$\mathbf{Salario}_i = \beta_0 + \beta_1 \, \mathbf{Escolaridad}_i + u_i$$

donde

- $\mathbf{Salario}_i$ es una variable continua que mide el salario de un individuo
- $\mathbf{Escolaridad}_i$ es una variable continua que mide los años de educación

Interpretaciones

- β_0: el intercepto en y, *es decir*, el $\mathbf{Salario}$ cuando $\mathbf{Escolaridad} = 0$
- β_1: el aumento esperado en el $\mathbf{Salario}$ por un aumento de una unidad en $\mathbf{Escolaridad}$

Interpretando coeficientes

Variables continuas

Derivando la interpretación de la pendiente:

$$\begin{aligned}\boldsymbol{E}[\text{Salario}|\text{Escolaridad} = \ell + 1] - \boldsymbol{E}[\text{Salario}|\text{Escolaridad} = \ell] = \\ \boldsymbol{E}[\beta_0 + \beta_1(\ell + 1) + u] - \boldsymbol{E}[\beta_0 + \beta_1\ell + u] = \\ [\beta_0 + \beta_1(\ell + 1)] - [\beta_0 + \beta_1\ell] = \\ \beta_0 - \beta_0 + \beta_1\ell - \beta_1\ell + \beta_1 = \beta_1\end{aligned}$$

Interpretando coeficientes

Variables continuas

Derivando la interpretación de la pendiente:

$$\begin{aligned}\boldsymbol{E}[\text{Salario}|\text{Escolaridad} = \ell + 1] - \boldsymbol{E}[\text{Salario}|\text{Escolaridad} = \ell] = \\ \boldsymbol{E}[\beta_0 + \beta_1(\ell + 1) + u] - \boldsymbol{E}[\beta_0 + \beta_1\ell + u] = \\ [\beta_0 + \beta_1(\ell + 1)] - [\beta_0 + \beta_1\ell] = \\ \beta_0 - \beta_0 + \beta_1\ell - \beta_1\ell + \beta_1 = \beta_1\end{aligned}$$

Es decir, la pendiente da el aumento esperado en nuestra variable de resultado por un aumento de una unidad en la variable explicativa.

Interpretando coeficientes

Variables continuas

Si tenemos múltiples variables explicativas, *por ejemplo*,

$$\mathbf{Salario}_i = \beta_0 + \beta_1 \mathbf{Escolaridad}_i + \beta_2 \mathbf{Habilidad}_i + u_i$$

entonces la interpretación cambia ligeramente.

Interpretando coeficientes

Variables continuas

Si tenemos múltiples variables explicativas, *por ejemplo*,

$$\mathrm{Salario}_i = \beta_0 + \beta_1 \, \mathrm{Escolaridad}_i + \beta_2 \, \mathrm{Habilidad}_i + u_i$$

entonces la interpretación cambia ligeramente.

$$\begin{aligned}
\boldsymbol{E}[\mathrm{Salario} | \mathrm{Escolaridad} = \ell + 1 \wedge \mathrm{Habilidad} = \alpha] - \\
\boldsymbol{E}[\mathrm{Salario} | \mathrm{Escolaridad} = \ell \wedge \mathrm{Habilidad} = \alpha] = \\
\boldsymbol{E}[\beta_0 + \beta_1(\ell + 1) + \beta_2 \alpha + u] - \boldsymbol{E}[\beta_0 + \beta_1 \ell + \beta_2 \alpha + u] = \\
[\beta_0 + \beta_1(\ell + 1) + \beta_2 \alpha] - [\beta_0 + \beta_1 \ell + \beta_2 \alpha] = \\
\beta_0 - \beta_0 + \beta_1 \ell - \beta_1 \ell + \beta_1 + \beta_2 \alpha - \beta_2 \alpha = \beta_1
\end{aligned}$$

Interpretando coeficientes

Variables continuas

Si tenemos múltiples variables explicativas, *por ejemplo*,

$$\text{Salario}_i = \beta_0 + \beta_1 \text{Escolaridad}_i + \beta_2 \text{Habilidad}_i + u_i$$

entonces la interpretación cambia ligeramente.

$$\begin{aligned}
\boldsymbol{E}[\text{Salario}|\text{Escolaridad} = \ell + 1 \wedge \text{Habilidad} = \alpha] - \\
\boldsymbol{E}[\text{Salario}|\text{Escolaridad} = \ell \wedge \text{Habilidad} = \alpha] = \\
\boldsymbol{E}[\beta_0 + \beta_1(\ell + 1) + \beta_2\alpha + u] - \boldsymbol{E}[\beta_0 + \beta_1\ell + \beta_2\alpha + u] = \\
[\beta_0 + \beta_1(\ell + 1) + \beta_2\alpha] - [\beta_0 + \beta_1\ell + \beta_2\alpha] = \\
\beta_0 - \beta_0 + \beta_1\ell - \beta_1\ell + \beta_1 + \beta_2\alpha - \beta_2\alpha = \beta_1
\end{aligned}$$

Es decir, la pendiente da el aumento esperado en nuestra variable de resultado por un aumento de una unidad en la variable explicativa, **manteniendo todas las demás variables constantes** (*ceteris paribus*).

Interpretando coeficientes

Variables continuas

Derivación alternativa

Considera el modelo

$$y = \beta_0 + \beta_1 x + u$$

Diferencia el modelo:

$$\frac{dy}{dx} = \beta_1$$

Interpretando coeficientes

Variables categóricas

Considera la relación

$$\text{Salario}_i = \beta_0 + \beta_1 \, \text{Mujer}_i + u_i$$

donde

- Salario_i es una variable continua que mide el salario de un individuo
- Mujer_i es una variable binaria/indicadora que toma el valor 1 cuando i es mujer

Interpretando coeficientes

Variables categóricas

Considera la relación

$$\text{Salario}_i = \beta_0 + \beta_1 \, \text{Mujer}_i + u_i$$

donde

- Salario_i es una variable continua que mide el salario de un individuo
- Mujer_i es una variable binaria/indicadora que toma el valor 1 cuando i es mujer

Interpretaciones

- β_0: el Salario esperado para los hombres (*es decir*, cuando $\text{Mujer} = 0$)
- β_1: la diferencia esperada en el Salario entre mujeres y hombres
- $\beta_0 + \beta_1$: el Salario esperado para las mujeres

Interpretando coeficientes

Variables categóricas

Derivaciones

$$\begin{aligned}\boldsymbol{E}[\text{Salario}|\text{Hombre}] &= \boldsymbol{E}[\beta_0 + \beta_1 \times 0 + u_i] \\ &= \boldsymbol{E}[\beta_0 + 0 + u_i] \\ &= \beta_0\end{aligned}$$

Interpretando coeficientes

Variables categóricas

Derivaciones

$$\begin{aligned}\boldsymbol{E}[\text{Salario}|\text{Hombre}] &= \boldsymbol{E}[\beta_0 + \beta_1 \times 0 + u_i] \\ &= \boldsymbol{E}[\beta_0 + 0 + u_i] \\ &= \beta_0\end{aligned}$$

$$\begin{aligned}\boldsymbol{E}[\text{Salario}|\text{Mujer}] &= \boldsymbol{E}[\beta_0 + \beta_1 \times 1 + u_i] \\ &= \boldsymbol{E}[\beta_0 + \beta_1 + u_i] \\ &= \beta_0 + \beta_1\end{aligned}$$

Interpretando coeficientes

Variables categóricas

Derivaciones

$$\begin{aligned}\boldsymbol{E}[\text{Salario}|\text{Hombre}] &= \boldsymbol{E}[\beta_0 + \beta_1 \times 0 + u_i] \\ &= \boldsymbol{E}[\beta_0 + 0 + u_i] \\ &= \beta_0\end{aligned}$$

$$\begin{aligned}\boldsymbol{E}[\text{Salario}|\text{Mujer}] &= \boldsymbol{E}[\beta_0 + \beta_1 \times 1 + u_i] \\ &= \boldsymbol{E}[\beta_0 + \beta_1 + u_i] \\ &= \beta_0 + \beta_1\end{aligned}$$

Nota: Si no hay otras variables para condicionar, entonces $\hat{\beta}_1$ es igual a la diferencia de medias entre grupos, *por ejemplo*, $\overline{x}_{\text{Mujer}} - \overline{x}_{\text{Hombre}}$.

Interpretando coeficientes

Variables categóricas

Derivaciones

$$\begin{aligned}\boldsymbol{E}[\text{Salario}|\text{Hombre}] &= \boldsymbol{E}[\beta_0 + \beta_1 \times 0 + u_i] \\ &= \boldsymbol{E}[\beta_0 + 0 + u_i] \\ &= \beta_0\end{aligned}$$

$$\begin{aligned}\boldsymbol{E}[\text{Salario}|\text{Mujer}] &= \boldsymbol{E}[\beta_0 + \beta_1 \times 1 + u_i] \\ &= \boldsymbol{E}[\beta_0 + \beta_1 + u_i] \\ &= \beta_0 + \beta_1\end{aligned}$$

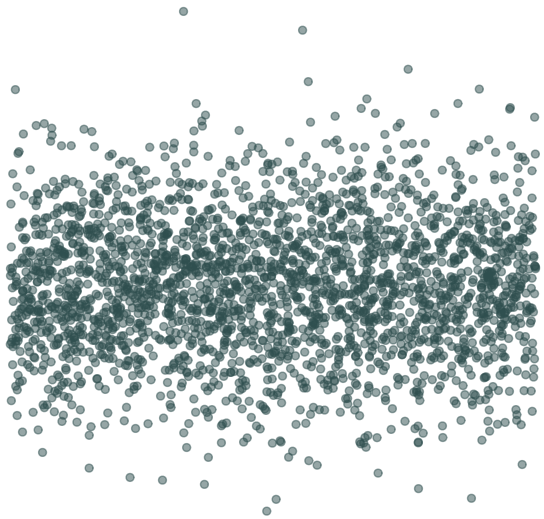
Nota: Si no hay otras variables para condicionar, entonces $\hat{\beta}_1$ es igual a la diferencia de medias entre grupos, *por ejemplo*, $\overline{x}_{\text{Mujer}} - \overline{x}_{\text{Hombre}}$.

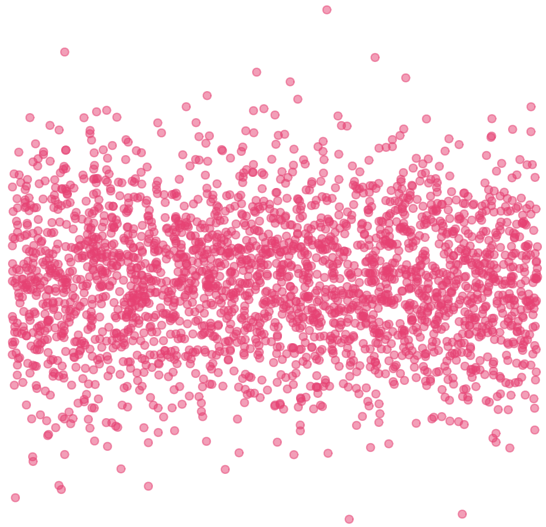
Nota$_2$: La interpretación de *mantener todas las demás variables constantes* también aplica para variables categóricas en contextos de regresión múltiple.

Interpretando coeficientes

Variables categóricas

$y_i = \beta_0 + \beta_1 x_i + u_i$ para la variable binaria $x_i = \{0, 1\}$

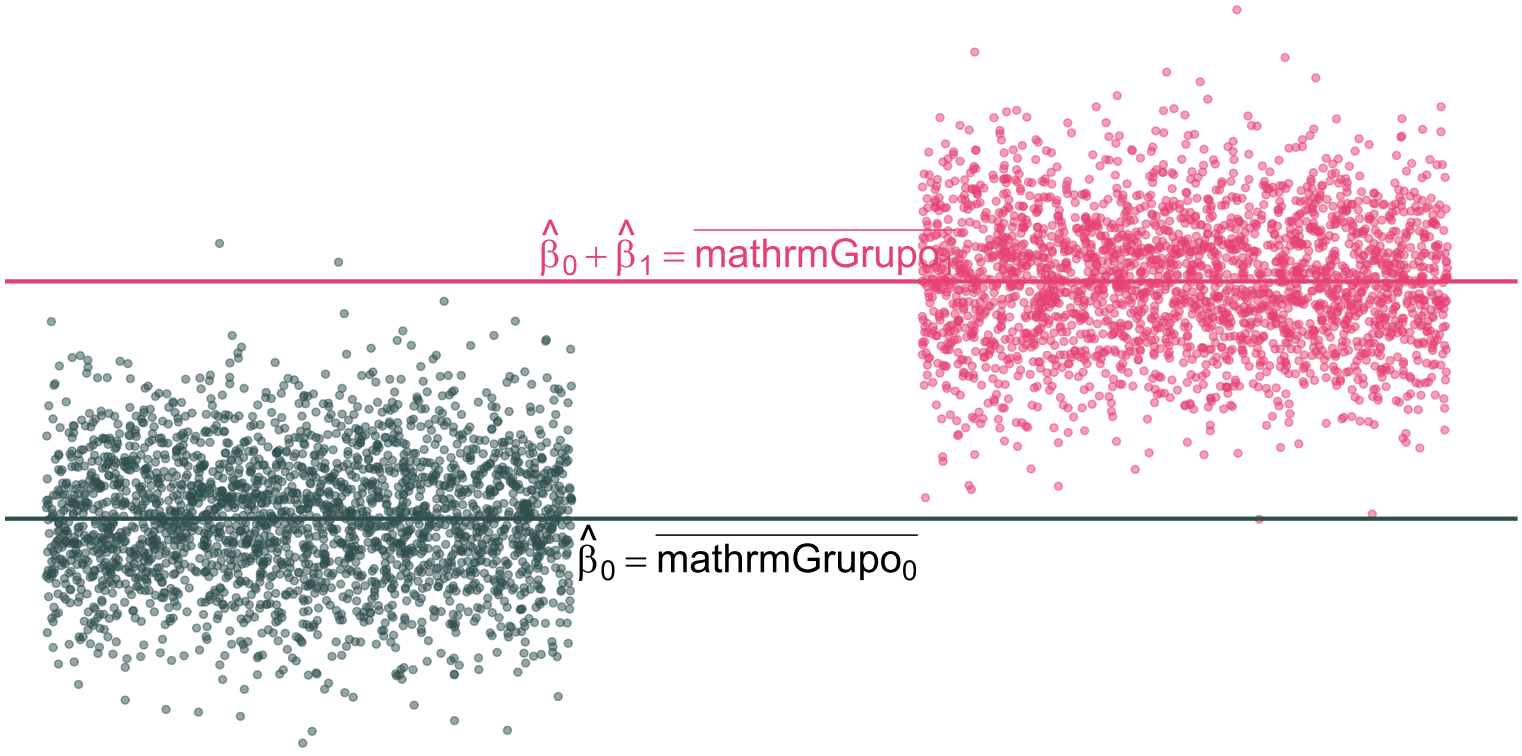




Interpretando coeficientes

Variables categóricas

$y_i = \beta_0 + \beta_1 x_i + u_i$ para la variable binaria $x_i = \{0, 1\}$



Interpretando coeficientes

Interacciones

Las interacciones permiten que el efecto de una variable cambie según el nivel de otra variable.

Ejemplos

1. ¿Cambia el efecto de la escolaridad sobre el salario según el género?
2. ¿Cambia el efecto del género sobre el salario según la raza?
3. ¿Cambia el efecto de la escolaridad sobre el salario según la experiencia?

Interpretando coeficientes

Interacciones

Anteriormente, consideramos un modelo que permitía que mujeres y hombres tuvieran salarios distintos, pero el modelo asumía que el efecto de la escolaridad sobre el salario era el mismo para todos:

$$\mathbf{Salario}_i = \beta_0 + \beta_1 \mathbf{Escolaridad}_i + \beta_2 \mathbf{Mujer}_i + u_i$$

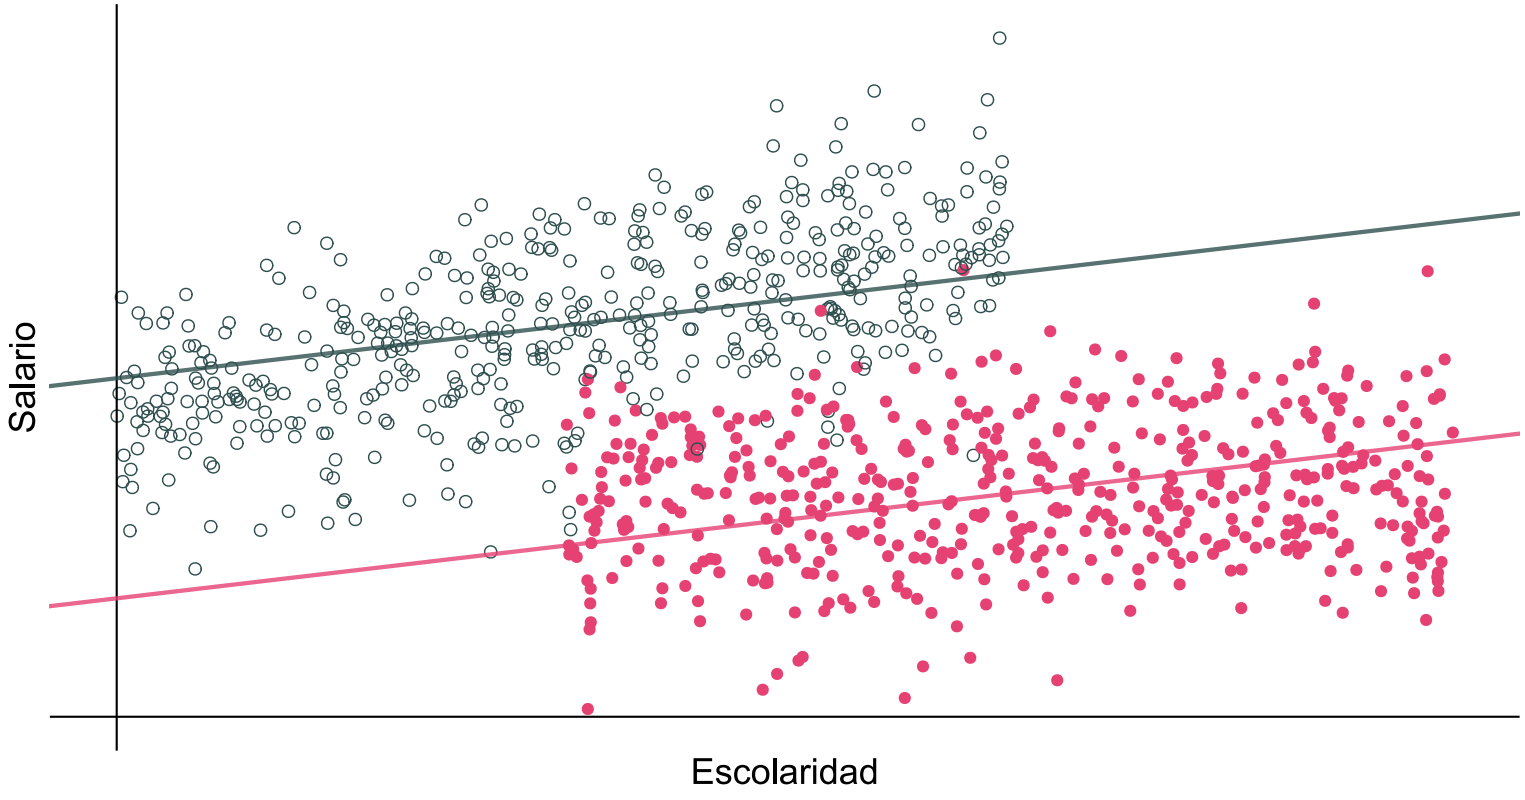
pero también podemos permitir que el efecto de la escolaridad varíe según el género:

$$\mathbf{Salario}_i = \beta_0 + \beta_1 \mathbf{Escolaridad}_i + \beta_2 \mathbf{Mujer}_i + \beta_3 \mathbf{Escolaridad}_i \times \mathbf{Mujer}_i + u_i$$

Interpretando coeficientes

Interacciones

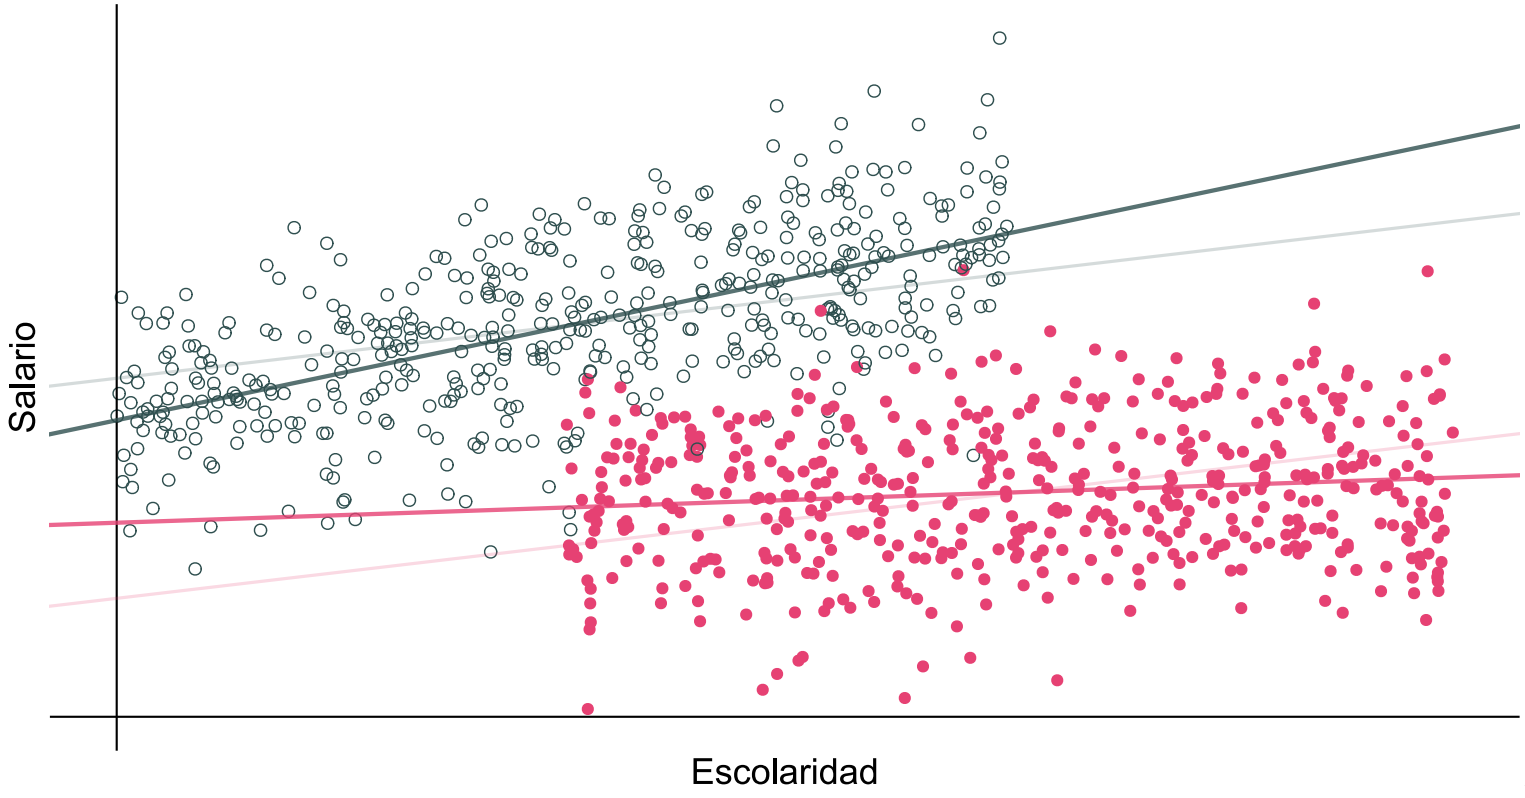
El modelo donde la escolaridad tiene el mismo efecto para todos (M y H):



Interpretando coeficientes

Interacciones

El modelo donde el efecto de la escolaridad puede diferir según el género (M y H):



Interpretando coeficientes

Interacciones

Interpretar coeficientes puede ser un poco complicado con interacciones, pero la clave[†] es trabajar cuidadosamente el álgebra.

$$\mathbf{Salario}_i = \beta_0 + \beta_1 \mathbf{Escolaridad}_i + \beta_2 \mathbf{Mujer}_i + \beta_3 \mathbf{Escolaridad}_i \times \mathbf{Mujer}_i + u_i$$

Retorno esperado de un año adicional de escolaridad para las mujeres:

$$\begin{aligned} &\boldsymbol{E}[\mathbf{Salario}_i | \mathbf{Mujer} \wedge \mathbf{Escolaridad} = \ell + 1] \\ &- \boldsymbol{E}[\mathbf{Salario}_i | \mathbf{Mujer} \wedge \mathbf{Escolaridad} = \ell] = \\ &\boldsymbol{E}[\beta_0 + \beta_1(\ell + 1) + \beta_2 + \beta_3(\ell + 1) + u_i] - \boldsymbol{E}[\beta_0 + \beta_1 \ell + \beta_2 + \beta_3 \ell + u_i] = \\ &\beta_1 + \beta_3 \end{aligned}$$

† Como suele suceder en econometría.

Interpretando coeficientes

Interacciones

Interpretar coeficientes puede ser un poco complicado con interacciones, pero la clave[†] es trabajar cuidadosamente el álgebra.

$$\text{Salario}_i = \beta_0 + \beta_1 \text{Escolaridad}_i + \beta_2 \text{Mujer}_i + \beta_3 \text{Escolaridad}_i \times \text{Mujer}_i + u_i$$

Retorno esperado de un año adicional de escolaridad para las mujeres:

$$\begin{aligned} &\boldsymbol{E}[\text{Salario}_i | \text{Mujer} \wedge \text{Escolaridad} = \ell + 1] \\ &- \boldsymbol{E}[\text{Salario}_i | \text{Mujer} \wedge \text{Escolaridad} = \ell] = \\ &\boldsymbol{E}[\beta_0 + \beta_1(\ell + 1) + \beta_2 + \beta_3(\ell + 1) + u_i] - \boldsymbol{E}[\beta_0 + \beta_1 \ell + \beta_2 + \beta_3 \ell + u_i] = \\ &\beta_1 + \beta_3 \end{aligned}$$

El β_1 da el retorno esperado de un año adicional de escolaridad para los hombres. Por lo tanto, β_3 da la **diferencia en los retornos a la escolaridad** entre M y H.

† Como suele suceder en econometría.

Interpretando coeficientes

Especificación log-lineal

En economía, se verá frecuentemente variables de resultado en logaritmos con variables explicativas lineales (sin logaritmo), *por ejemplo*,

$$\log(\text{Salario}_i) = \beta_0 + \beta_1 \, \text{Escolaridad}_i + u_i$$

Esta especificación cambia nuestra interpretación de los coeficientes de pendiente.

Interpretación

- Un aumento de una unidad en nuestra variable explicativa aumenta la variable de resultado en aproximadamente $\beta_1 \times 100$ por ciento.
- *Ejemplo:* Un año adicional de escolaridad aumenta el salario en aproximadamente 3 por ciento (para $\beta_1 = 0.03$).

Interpretando coeficientes

Especificación log-lineal

Debido a que la especificación log-lineal viene con una interpretación diferente, necesitas asegurarte de que se ajuste a tu proceso generador de datos/modelo.

¿Si x cambia a y en niveles (*por ejemplo*, un aumento de 3 unidades) o en porcentajes (*por ejemplo*, un aumento del 10 por ciento)?

Interpretando coeficientes

Especificación log-lineal

Debido a que la especificación log-lineal viene con una interpretación diferente, necesitas asegurarte de que se ajuste a tu proceso generador de datos/modelo.

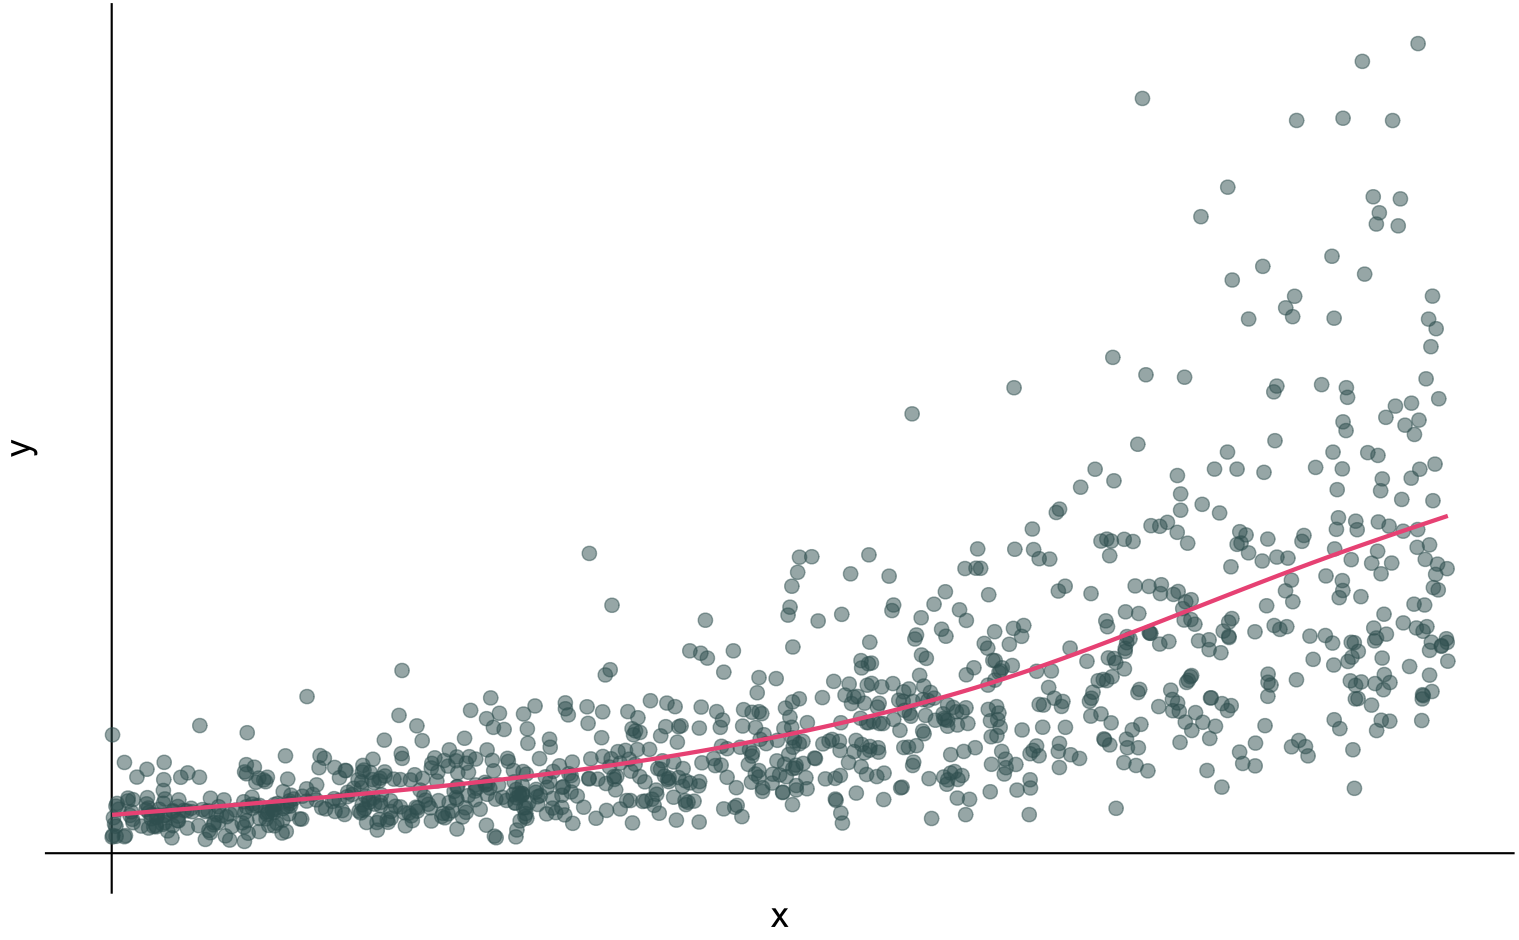
¿Si x cambia a y en niveles (*por ejemplo*, un aumento de 3 unidades) o en porcentajes (*por ejemplo*, un aumento del 10 por ciento)?

Es decir, necesitas asegurarte de que una relación exponencial tenga sentido:

$$\log(y_i) = \beta_0 + \beta_1 x_i + u_i \iff y_i = e^{\beta_0 + \beta_1 x_i + u_i}$$

Interpretando coeficientes

Especificación log-lineal



Interpretando coeficientes

Especificación log-log

De forma similar, los econometristas suelen usar modelos log-log, en los que la variable de resultado está en logaritmo *y* al menos una variable explicativa también

$$\log(\text{Salario}_i) = \beta_0 + \beta_1 \log(\text{Escolaridad}_i) + u_i$$

Interpretación:

- Un aumento de un uno por ciento en x generará un cambio de β_1 por ciento en y.
- Frecuentemente se interpreta como una elasticidad.

Interpretando coeficientes

Log-lineal con una variable binaria

Nota: Si tienes un modelo log-lineal con una variable indicadora binaria, la interpretación del coeficiente de esa variable cambia.

Considera

$$\log(y_i) = \beta_0 + \beta_1 x_1 + u_i$$

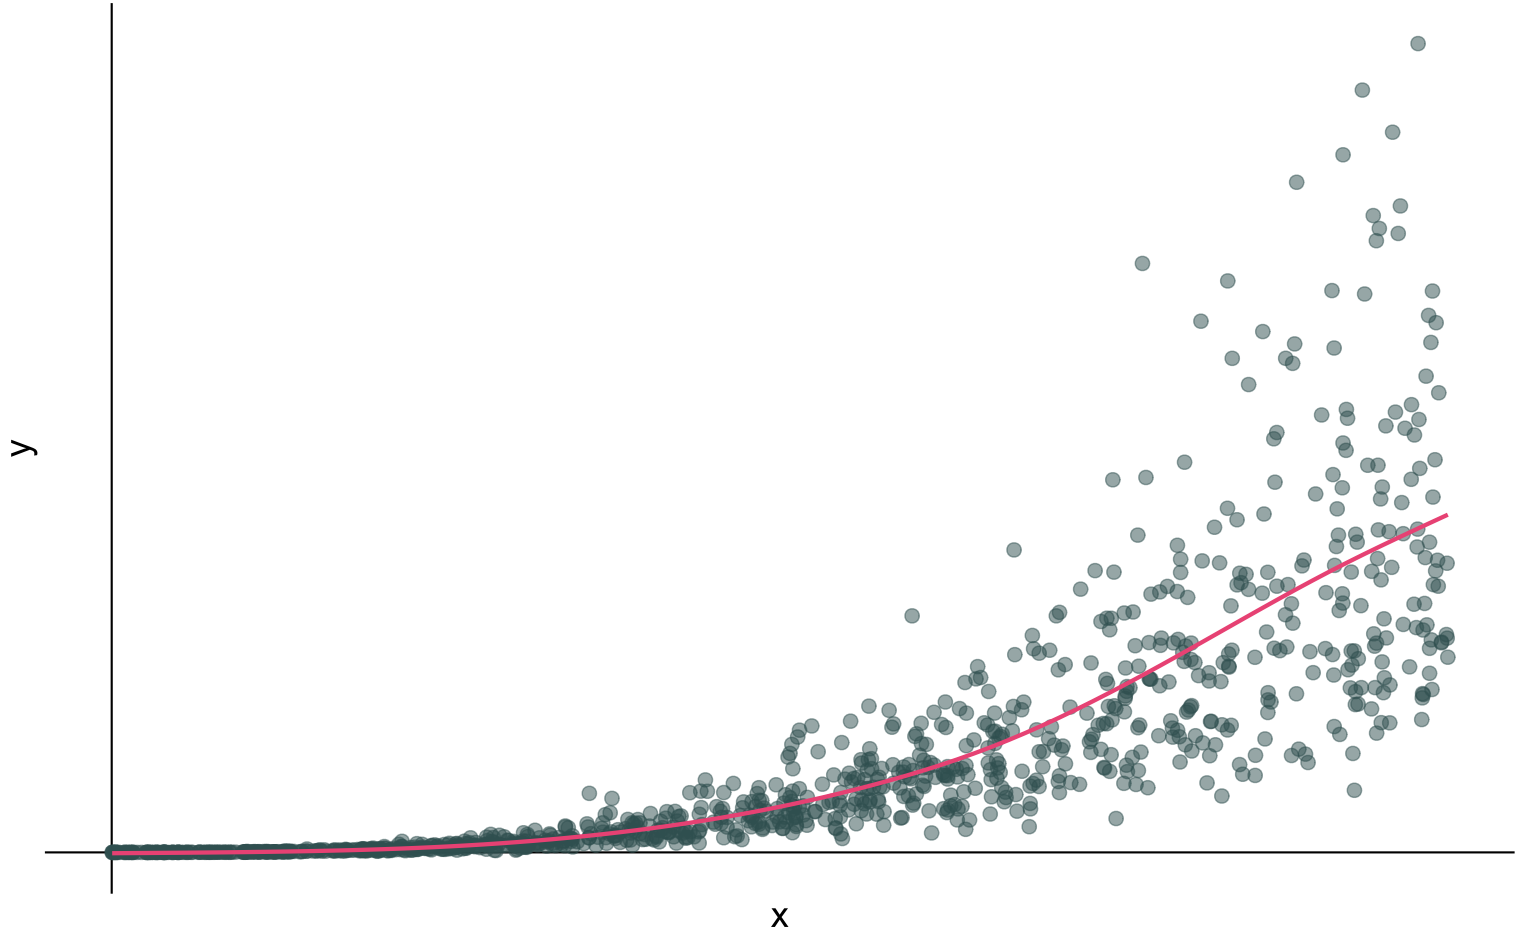
para la variable binaria x_1.

La interpretación de β_1 ahora es

- Cuando x_1 cambia de 0 a 1, y cambiará en $100 \times \left(e^{\beta_1} - 1\right)$ por ciento.
- Cuando x_1 cambia de 1 a 0, y cambiará en $100 \times \left(e^{-\beta_1} - 1\right)$ por ciento.

Interpretando coeficientes

Especificación log-log



Temas adicionales

Temas adicionales

MCRLM: enfoque matricial

El Modelo Clásico de Regresión Lineal Múltiple (MCRLM) en forma matricial es:

$$Y = X\beta + U$$

donde Y es el vector $n \times 1$ de la variable dependiente, X la matriz $n \times k$ de regresores (incluye una columna de unos para el intercepto), β el vector $k \times 1$ de parámetros y U el vector $n \times 1$ de perturbaciones.

Estimador de mínimos cuadrados ordinarios (MCO)

Suma de cuadrados de los residuos. Despejando el error, $U = Y - X\hat{\beta}$, y la suma de cuadrados de los residuos es:

$$\sum u_i^2 = U^t U = (Y - X\hat{\beta})^t (Y - X\hat{\beta})$$

Temas adicionales

Demostración.Partimos del modelo y despejamos el vector de errores:

$$Y = X\beta + U \quad \Rightarrow \quad U = Y - X\hat{\beta}$$

La suma de cuadrados de los residuos es:

$$\sum u_i^2 = U^t U = (Y - X\hat{\beta})^t (Y - X\hat{\beta})$$

Usando la propiedad de la transpuesta $(AB)^t = B^t A^t$:

$$U^t U = (Y^t - \hat{\beta}^t X^t)(Y - X\hat{\beta})$$

$$U^t U = Y^t Y - Y^t X\hat{\beta} - \hat{\beta}^t X^t Y + \hat{\beta}^t X^t X\hat{\beta}$$

Como $Y^t X\hat{\beta}$ es un escalar, es igual a su transpuesta $\hat{\beta}^t X^t Y$:

$$U^t U = Y^t Y - 2\hat{\beta}^t X^t Y + \hat{\beta}^t X^t X\hat{\beta}$$

Temas adicionales

Condición de primer orden

Derivando respecto de $\hat{\beta}$ e igualando a cero:

$$\frac{\partial U^t U}{\partial \hat{\beta}} = -2X^tY + 2X^tX\hat{\beta} = 0$$

$$2X^tY = 2X^tX\hat{\beta} \quad \Rightarrow \quad X^tY = X^tX\hat{\beta}$$

Premultiplicando por $(X^tX)^{-1}$ y usando $A^{-1}A = I$:

$$(X^tX)^{-1}X^tY = (X^tX)^{-1}X^tX\hat{\beta}$$

$$\boxed{\hat{\beta} = (X^tX)^{-1}X^tY}$$

Temas adicionales

Matriz de varianzas y covarianzas

Por lo tanto, la matriz de varianzas y covarianzas del estimador es:

$$V(\hat{\beta}) = \sigma_u^2 \, (X^t X)^{-1}$$

Como σ_u^2 es desconocida, se estima con:

$$\hat{\sigma}_u^2 = \frac{U^t U}{n-k} = \frac{SRC}{n-k}$$

Temas adicionales

Sumas de cuadrados

Así también se definen:

$$STC = Y^tY - n\bar{Y}^2 \qquad (\text{suma total de cuadrados})$$

$$SEC = \hat{\beta}^t X^tY - n\bar{Y}^2 \qquad (\text{suma explicada de cuadrados})$$

$$SRC = Y^tY - \hat{\beta}^t X^tY \qquad (\text{suma residual de cuadrados})$$

Se cumple la descomposición $STC = SEC + SRC$, y de ella el coeficiente de determinación:

$$R^2 = \frac{SEC}{STC} = 1 - \frac{SRC}{STC}$$

Temas adicionales

Aplicación en R. A continuación se calculan todas las expresiones anteriores con datos simulados y se comparan con `lm()`.

Datos

```
set.seed(123); n  ← 60; x1 ← rnorm(n, 10, 2); x2 ← rnorm(n, 5, 1); y  ← 4 +
X ← cbind(Intercepto = 1, x1 = x1, x2 = x2); Y ← matrix(y, ncol = 1); k ← nco
dim(X)
```

```
#> [1] 60  3
```

```
head(X)
```

```
#>      Intercepto        x1       x2
#> [1,]          1  8.879049 5.379639
#> [2,]          1  9.539645 4.497677
#> [3,]          1 13.117417 4.666793
#> [4,]          1 10.141017 3.981425
#> [5,]          1 10.258575 3.928209
#> [6,]          1 13.430130 5.303529
```

Temas adicionales

Estimador MCO

```
XtX ← t(X) %*% X
XtY ← t(X) %*% Y

B ← solve(XtX) %*% XtY       # B = (X'X)^-1 X'Y
B
```

```
#>                  [,1]
#> Intercepto  3.2842159
#> x1          1.3226542
#> x2         -0.9091152
```

Temas adicionales

Sumas de cuadrados y R^2

```
ybar ← mean(Y)

STC ← as.numeric(t(Y) %*% Y - n * ybar^2)
SEC ← as.numeric(t(B) %*% XtY - n * ybar^2)
SRC ← as.numeric(t(Y) %*% Y - t(B) %*% XtY)

data.frame(
  medida = c("STC", "SEC", "SRC", "SEC + SRC", "R^2"),
  valor  = c(STC, SEC, SRC, SEC + SRC, SEC / STC)
)
```

```
#>       medida       valor
#> 1        STC 417.1060039
#> 2        SEC 354.6426142
#> 3        SRC  62.4633898
#> 4 SEC + SRC 417.1060039
#> 5        R^2   0.8502458
```

Temas adicionales

Matriz de varianzas y covarianzas

```
sigma2 ← SRC / (n - k)
VB ← sigma2 * solve(XtX)     # V(B) = sigma^2 (X'X)^-1
VB
```

```
#>              Intercepto           x1           x2
#> Intercepto  1.06359145 -0.050976792 -0.106513829
#> x1         -0.05097679  0.005673871 -0.001310408
#> x2         -0.10651383 -0.001310408  0.024125574
```

```
ee ← sqrt(diag(VB))          # errores estándar
ee
```

```
#> Intercepto          x1          x2
#>  1.0313057  0.0753251  0.1553241
```

Temas adicionales

Comparación con `lm()`

```
mod ← lm(y ~ x1 + x2)

comparacion ← data.frame(
  matricial = as.numeric(B),
  lm        = unname(coef(mod)),
  ee_matricial = ee,
  ee_lm        = unname(summary(mod)$coefficients[, "Std. Error"]),
  row.names = colnames(X)
)
comparacion
```

```
#>             matricial         lm ee_matricial     ee_lm
#> Intercepto  3.2842159  3.2842159    1.0313057 1.0313057
#> x1          1.3226542  1.3226542    0.0753251 0.0753251
#> x2         -0.9091152 -0.9091152    0.1553241 0.1553241
```

Temas adicionales

```
summary(mod)
```

```
#>
#> Call:
#> lm(formula = y ~ x1 + x2)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -1.95715 -0.80526  0.02068  0.68858  2.70587
#>
#> Coefficients:
#>             Estimate Std. Error t value Pr(>|t|)
#> (Intercept)  3.28422    1.03131   3.185  0.00235 **
#> x1           1.32265    0.07533  17.559  < 2e-16 ***
#> x2          -0.90912    0.15532  -5.853  2.5e-07 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 1.047 on 57 degrees of freedom
#> Multiple R-squared:  0.8502,    Adjusted R-squared:  0.845
#> F-statistic: 161.8 on 2 and 57 DF,  p-value: < 2.2e-16
```

Inferencia *vs.* predicción

Hasta ahora, nos hemos enfocado principalmente en la **inferencia estadística**—usando estimadores y las propiedades de sus distribuciones para intentar aprender sobre los parámetros poblacionales subyacentes, desconocidos.

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \cdots + \hat{\beta}_k x_{ki} + e_i$$

Inferencia *vs.* predicción

Hasta ahora, nos hemos enfocado principalmente en la **inferencia estadística**—usando estimadores y las propiedades de sus distribuciones para intentar aprender sobre los parámetros poblacionales subyacentes, desconocidos.

$$y_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \hat{\beta}_2 x_{2i} + \cdots + \hat{\beta}_k x_{ki} + e_i$$

La **predicción** incluye un conjunto de temas/herramientas bastante distinto dentro de la econometría (y la ciencia de datos/aprendizaje automático)—crear modelos que estimen con precisión observaciones individuales.

$$\hat{y}_i = \hat{f}\left(x_1, x_2, \ldots x_k\right)$$

Inferencia *vs.* predicción

En resumen

- **Inferencia:** causalidad, $\hat{\beta}_k$ (consistente y eficiente), errores estándar/pruebas de hipótesis para $\hat{\beta}_k$, generalmente MCO
- **Predicción:**[†] correlación, $\hat{y}_i$ (bajo error), selección de modelos, los modelos no lineales son mucho más comunes

† Incluye el pronóstico (forecasting).

Temas adicionales

Efectos de tratamiento y causalidad

Gran parte de la (micro)econometría moderna se enfoca en estimar causalmente (*identificar*) el efecto de programas/políticas, *por ejemplo*,

- El salario mínimo
- La legalización del cannabis recreativo
- Prohibiciones sobre el historial salarial
- Preescolar

Temas adicionales

Efectos de tratamiento y causalidad

Gran parte de la (micro)econometría moderna se enfoca en estimar causalmente (*identificar*) el efecto de programas/políticas, *por ejemplo*,

- El salario mínimo
- La legalización del cannabis recreativo
- Prohibiciones sobre el historial salarial
- Preescolar

En esta literatura, el programa suele ser una variable binaria, y le damos mucha importancia a encontrar una estimación insesgada del efecto del programa, $\hat{\tau}$.

$$\text{Resultado}_i = \beta_0 + \tau \, \text{Programa}_i + u_i$$

Transformaciones

Nuestro supuesto de linealidad requiere que

1. los **parámetros entren linealmente** (*es decir*, los β_k multiplicados por variables)
2. las perturbaciones u_i **entren de forma aditiva**

Permitimos relaciones no lineales entre y y las variables explicativas.

Temas adicionales

Transformaciones

Nuestro supuesto de linealidad requiere que

1. los **parámetros entren linealmente** (*es decir*, los β_k multiplicados por variables)
2. las perturbaciones u_i **entren de forma aditiva**

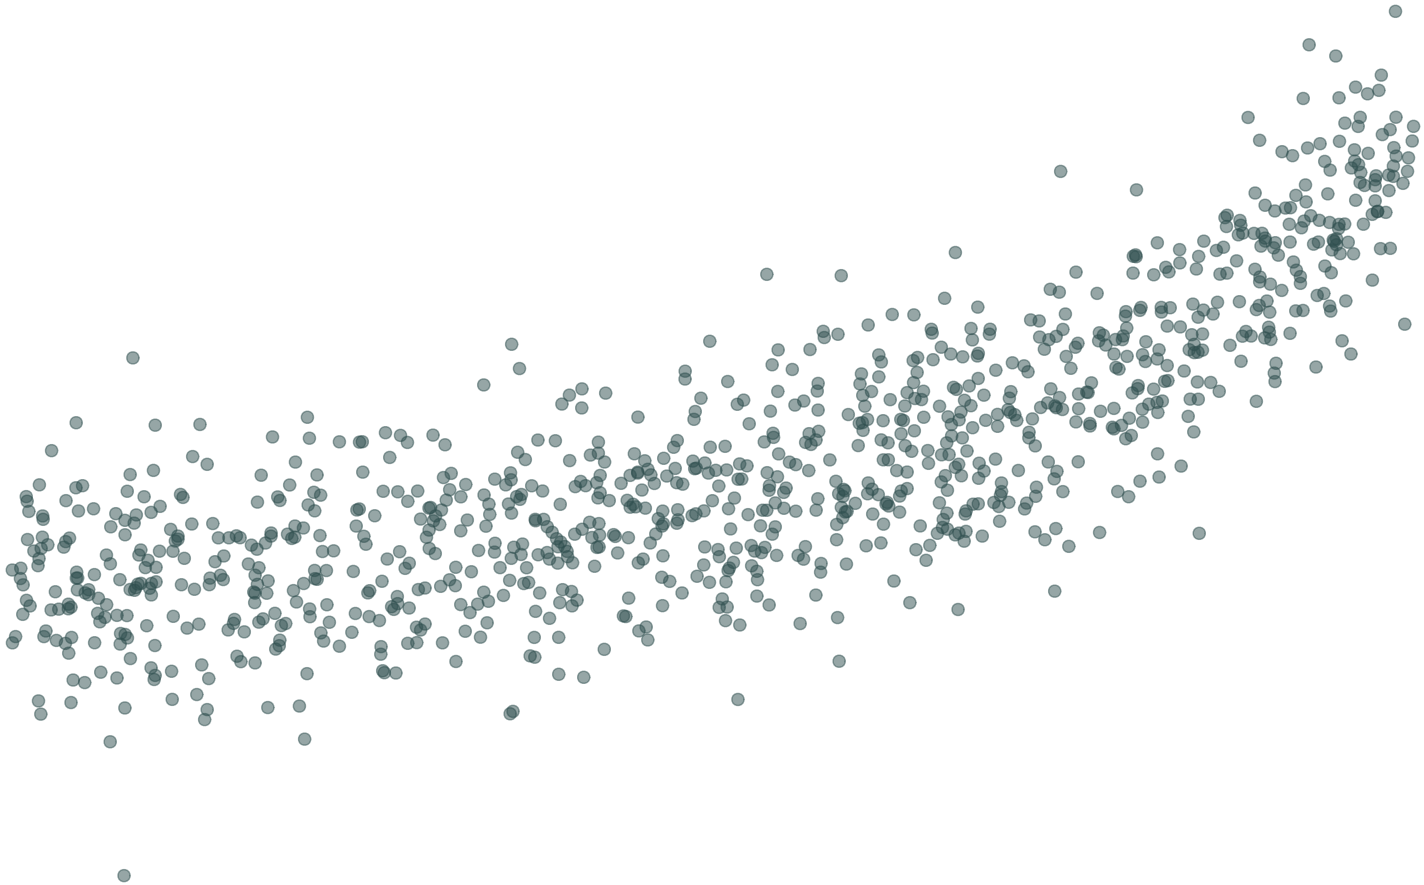
Permitimos relaciones no lineales entre y y las variables explicativas.

Ejemplos

- **Polinomios** e **interacciones:**
  $y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + \beta_3 x_2 + \beta_4 x_2^2 + \beta_5 (x_1 x_2) + u_i$
- **Exponenciales** y **logaritmos:** $\log(y_i) = \beta_0 + \beta_1 x_1 + \beta_2 e^{x_2} + u_i$
- **Indicadoras** y **umbrales:** $y_i = \beta_0 + \beta_1 x_1 + \beta_2 \mathbb{I}(x_1 \geq 100) + u_i$

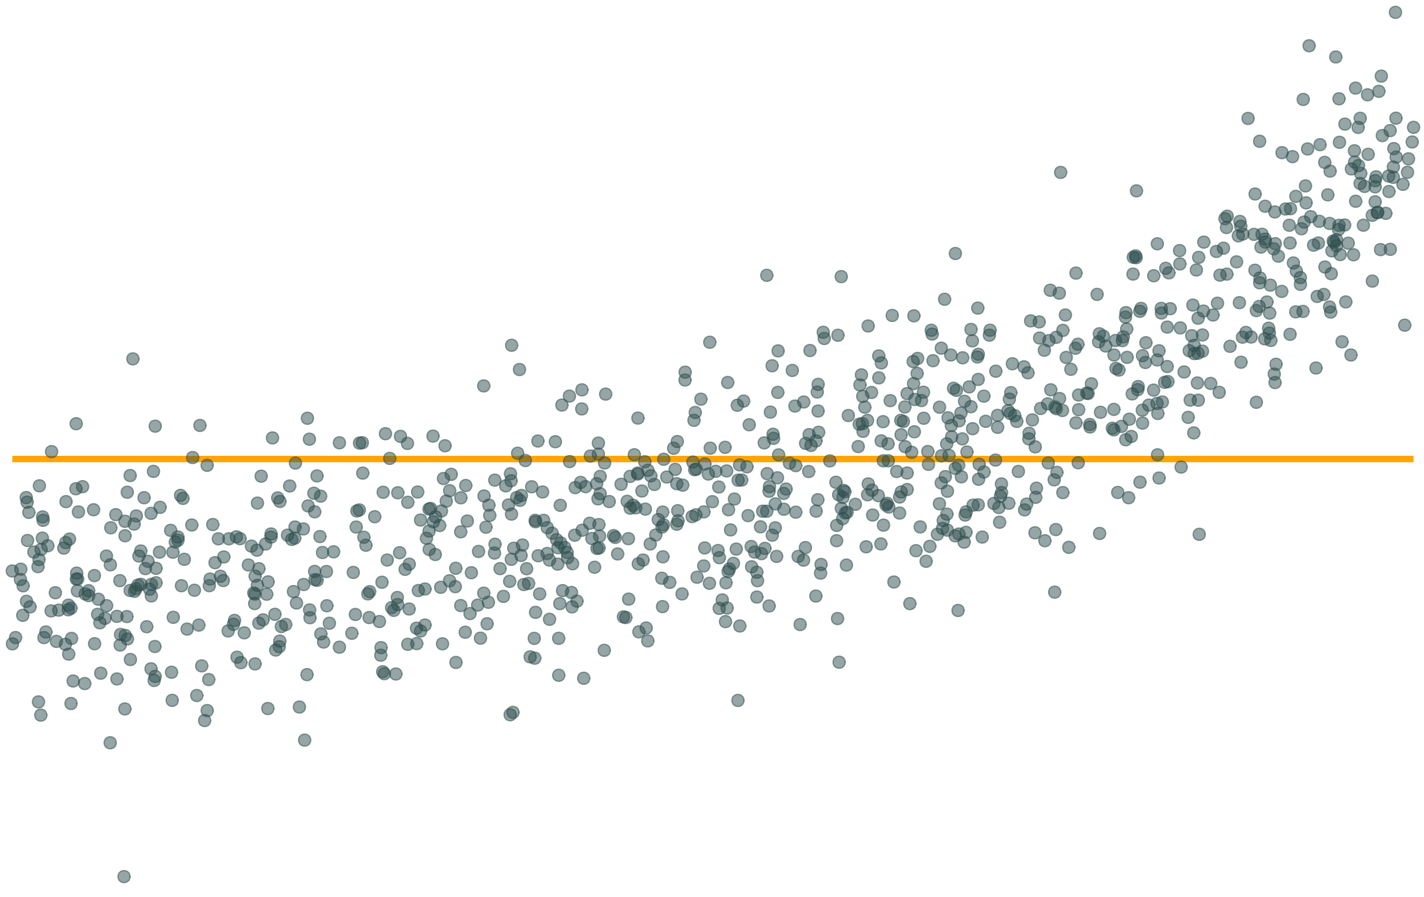
Temas adicionales

Desafío de transformación: posibilidades (literalmente) infinitas. ¿Cuál elegimos?



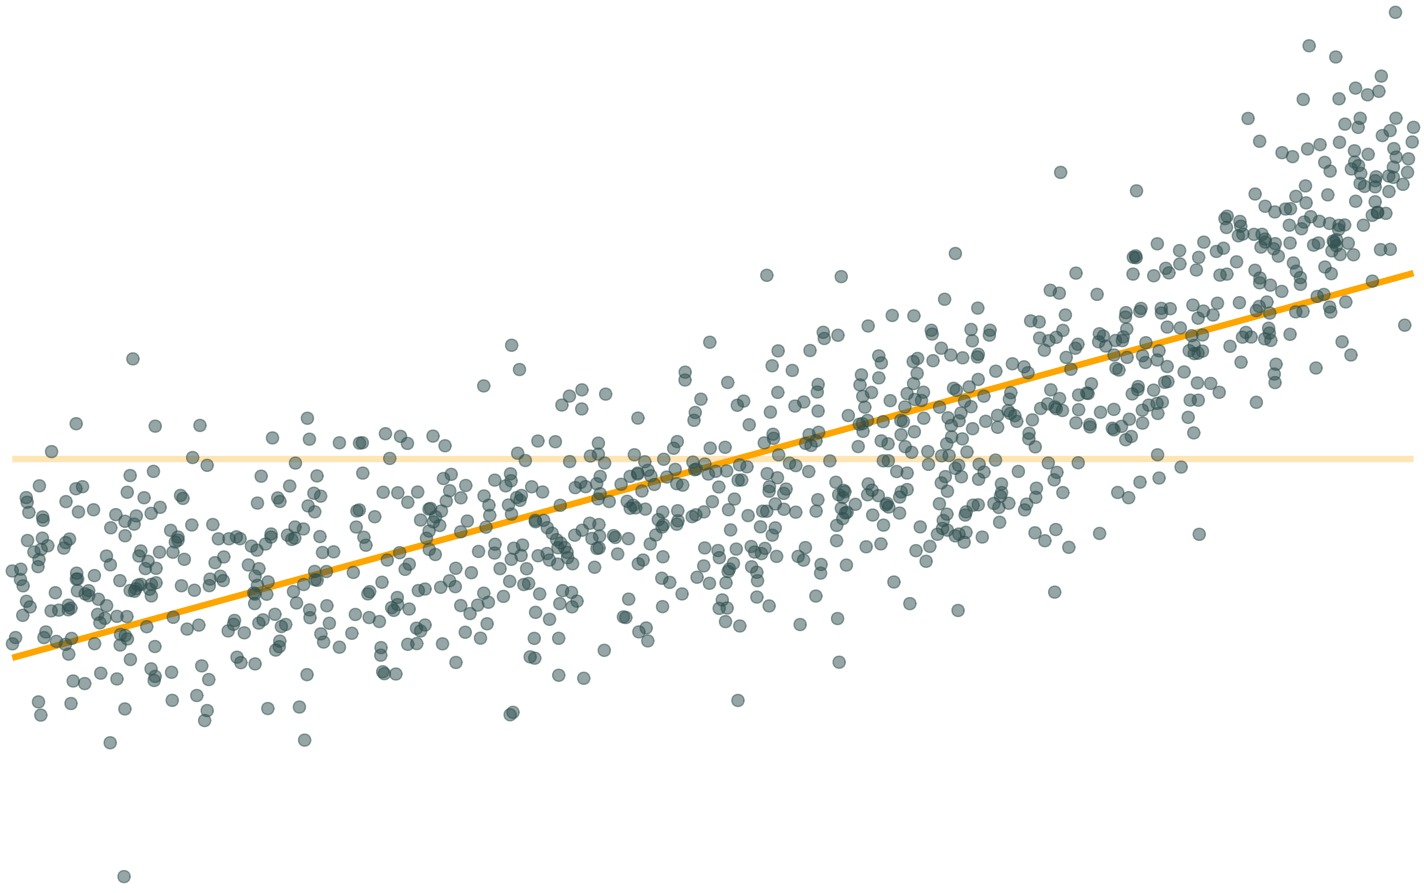
Temas adicionales

$$y_i = \beta_0 + u_i$$



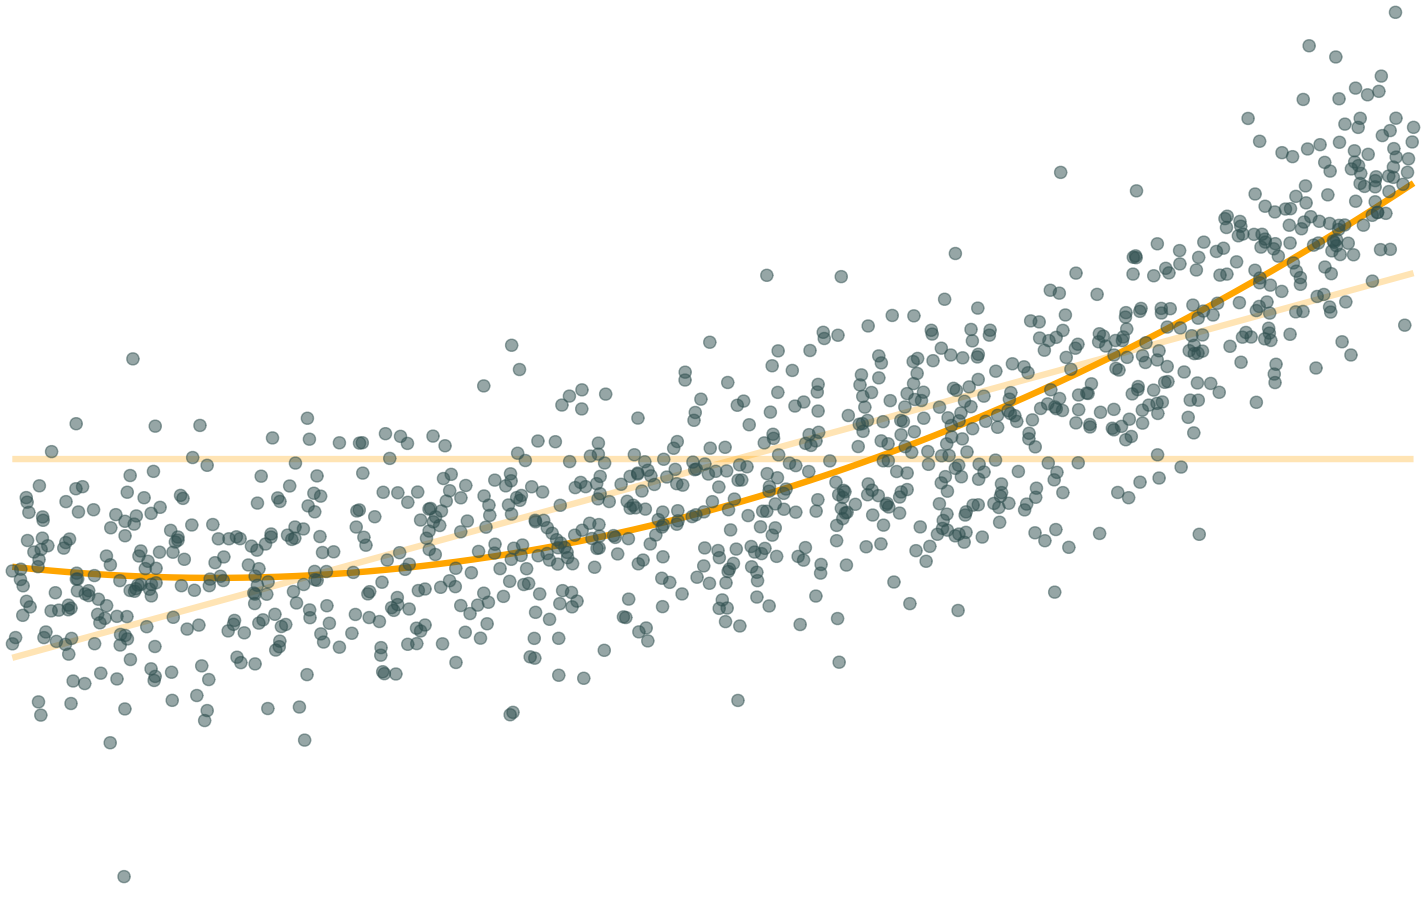
Temas adicionales

$$y_i = \beta_0 + \beta_1 x + u_i$$



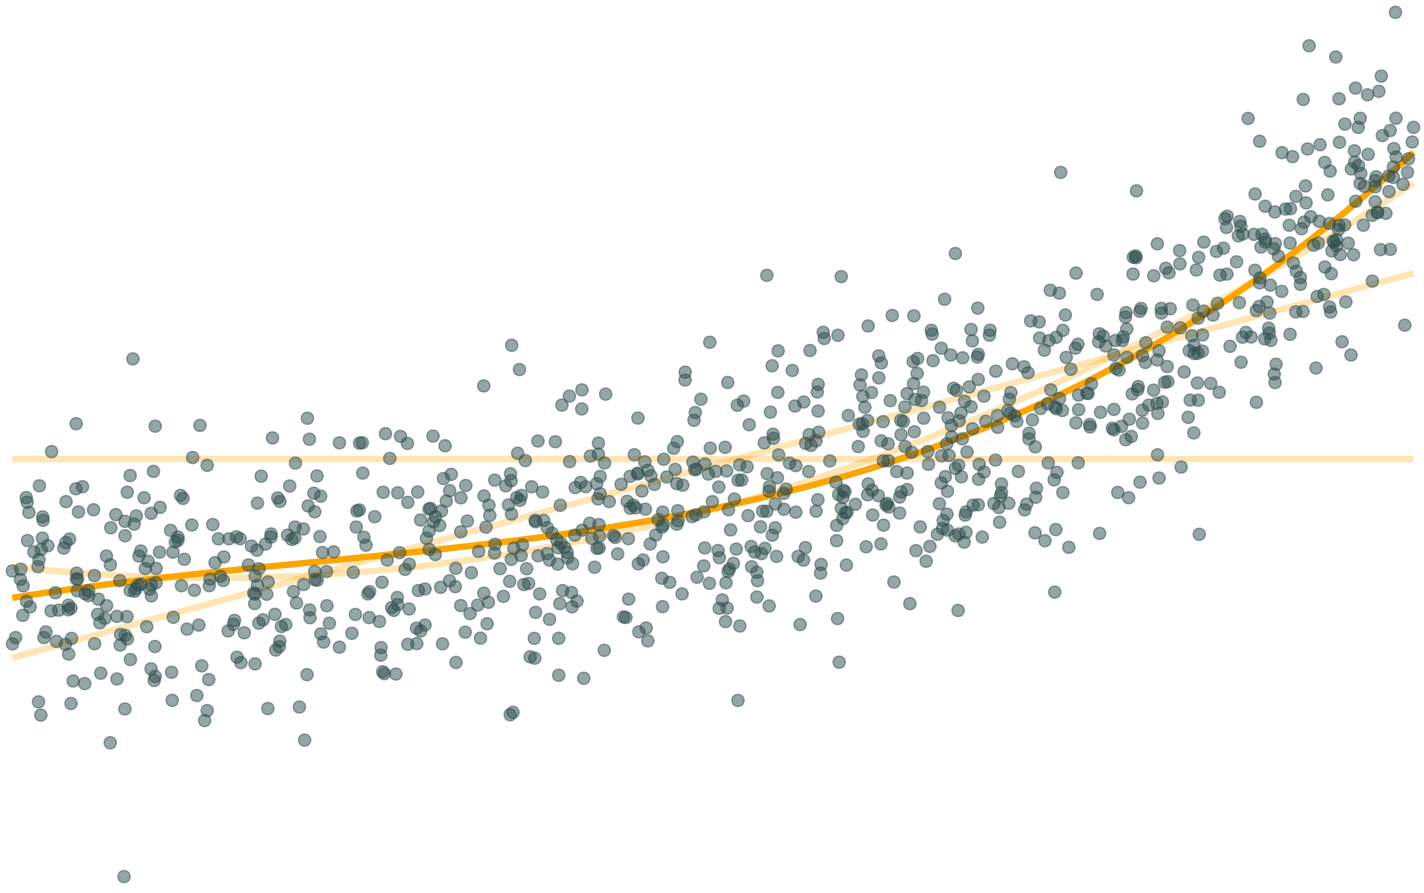
Temas adicionales

$$y_i = \beta_0 + \beta_1 x + \beta_2 x^2 + u_i$$



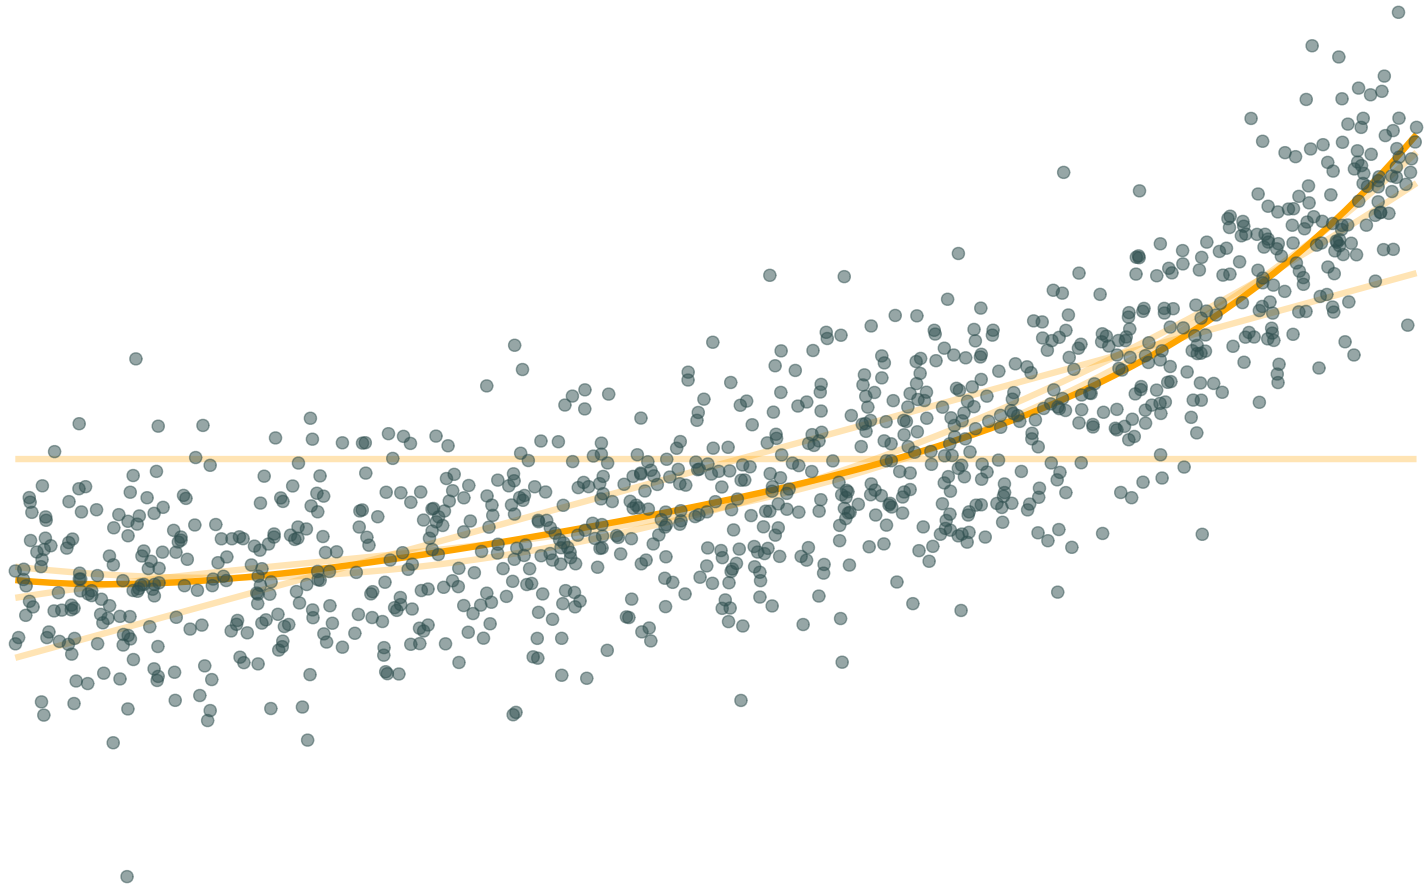
Temas adicionales

$$y_i = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + u_i$$



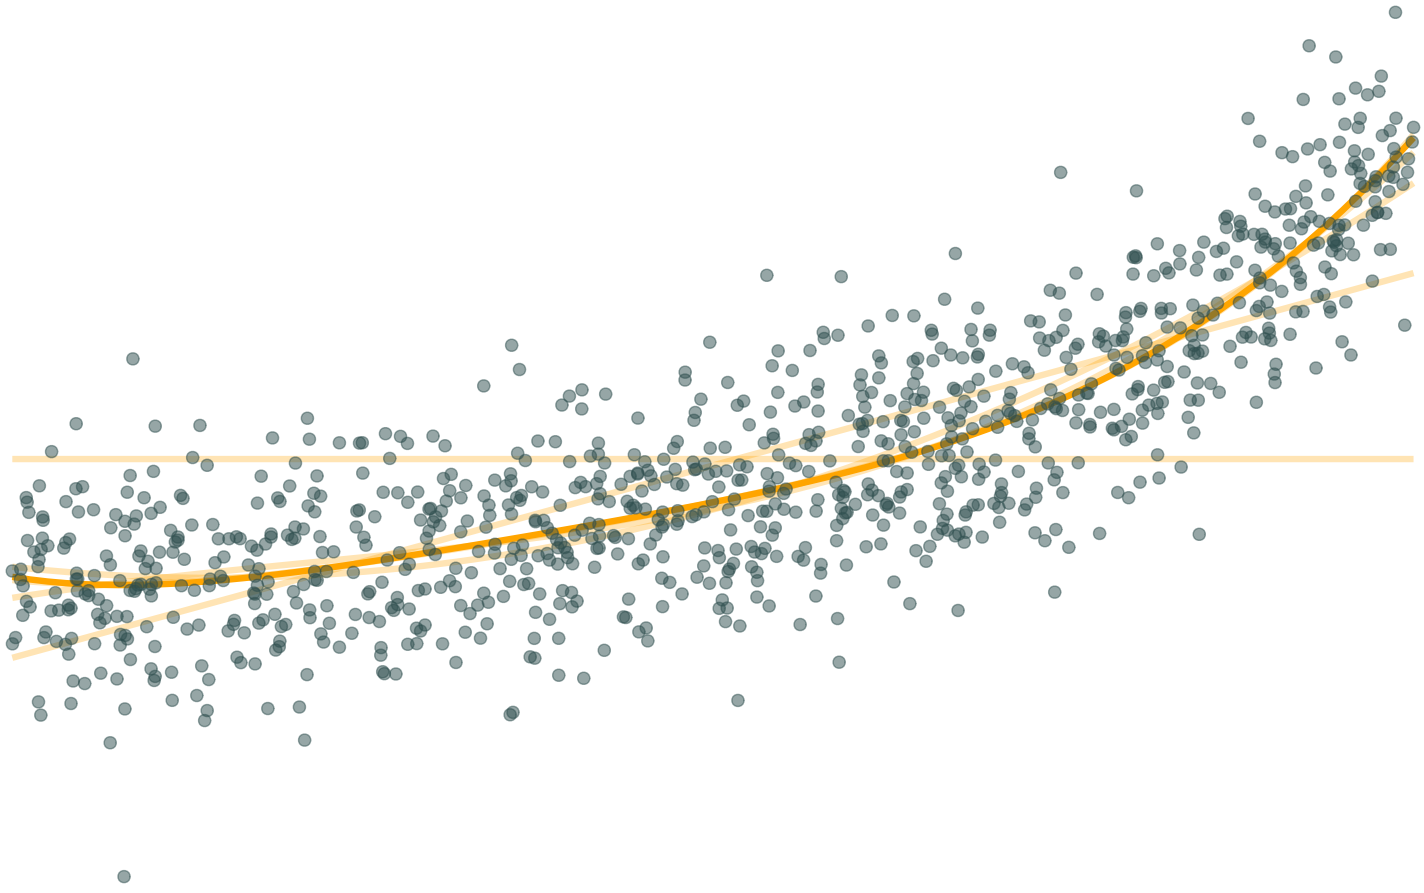
Temas adicionales

$$y_i = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4 + u_i$$



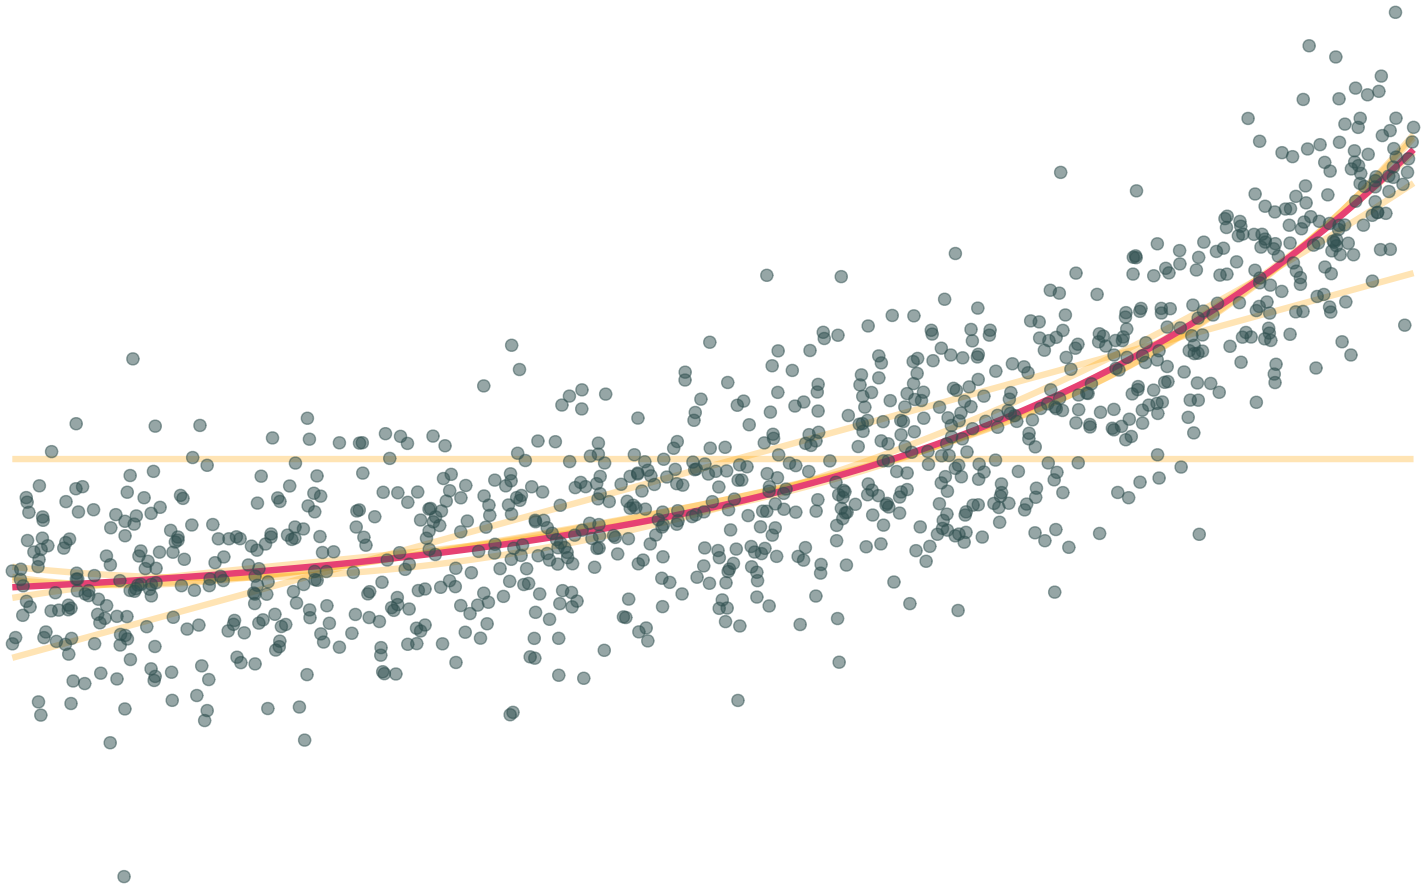
Temas adicionales

$$y_i = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4 + \beta_5 x^5 + u_i$$



Temas adicionales

La verdad: $y_i = 2e^x + u_i$



Temas adicionales

Valores atípicos (outliers)

Debido a que MCO minimiza la suma de los errores **al cuadrado**, los valores atípicos pueden influir mucho en nuestras estimaciones.

Respuestas comunes

- Remover los valores atípicos del conjunto de datos
- Reemplazar los valores atípicos con el percentil 99° de su variable (*winsorizar*)
- Tomar el logaritmo de la variable para "resolver" los valores atípicos
- No hacer nada. Los valores atípicos no siempre son malos. Algunas personas están "lejos" del promedio. Puede que no tenga sentido intentar cambiar esta variación.

Temas adicionales

Datos faltantes

De forma similar, los datos faltantes pueden afectar tus resultados.

R no sabe cómo lidiar con una observación faltante.

```
1 + 2 + 3 + NA + 5
```

```
#> [1] NA
```

Si corres una regresión[†] con valores faltantes, **R** descarta las observaciones a las que les faltan esos valores.

Si las observaciones faltan de forma no aleatoria, una muestra aleatoria puede terminar siendo no aleatoria.

[†]: O al realizar casi cualquier operación/función